重庆师范大学

硕士学位论文

集成式增量学习分类算法研究

熊霖

指导教师：唐万梅 教授

专业名称：软件工程

研究方向：机器学习

二〇一九年五月

中国知网 https://www.cnki.net

重庆师范大学硕士学位论文

集成式增量学习分类算法研究

硕士研究生：熊 霖

指导教师：唐万梅 教授

学科专业：软件工程

所在学院：计算机与信息科学学院

重庆师范大学

二零一九年五月

中国知网 https://www.cnki.net

A Thesis Submitted to Chongqing Normal University in Partial Fulfillment of the Requirements for the Degree of Master

The Research on Ensemble Incremental Learning Classification Algorithm

Candidate: Xiong Lin

Supervisor: Tang Wan-Mei Professor

Major: Software Engineering

College: College of Computer and Information Science

Chongqing Normal University

May, 2019

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

集成式增量学习分类算法研究

摘　　要

随着互联网、移动通信、物联网等领域的飞速发展，所产生的数据呈指数增长，数据的形式也从传统的静态数据向动态数据流形式转变，如何快速有效地获取数据流中蕴含的知识变得尤为重要。在现实生活中，环境的变化使得数据中蕴含的知识可能发生变化，传统的批量学习方法在处理动态变化的数据流时遇到了诸多挑战。因此，设计一种能实时地处理动态数据流的模型成为了迫切的需要。

增量学习是机器学习领域一个前沿的研究方向，它是指在保留绝大多数以前学到的知识的情况下学习新知识。早期研究的单分类器增量学习模型在学习过程中易产生“知识的遗忘”和存在稳定性差等问题，集成学习的引入有效的提高了增量学习的学习能力，但模型的规模更为庞大。本文采用集成多个基分类器构建集成模型，以对不断累积的数据进行增量学习，旨在建立一个高效精确的增量学习模型，以便对数据流进行预测。论文主要完成了以下工作：

第一，近年关于集成式增量学习的研究大多采用加权投票的方式将多个同质分类器进行结合，并没有很好的解决增量学习中的稳定-可塑性难题。针对此提出了一种异构分类器集成增量学习算法。该算法在训练过程中，为使模型更具稳定性，用新数据训练多个基分类器加入到异构的集成模型之中，同时采用局部敏感哈希表保存数据梗概以备待测样本近邻的查找；为了适应不断变化的数据，还会用新获得的数据更新集成模型中基分类器的投票权重；对待测样本进行类别预测时，以局部敏感哈希表中与待测样本相似的数据作为桥梁，计算基分类器针对该待测样本的动态权重，结合多个基分类器的投票权重和动态权重判定待测样本所属类别。通过对比实验，证明了该增量算法有比较高的稳定性和泛化能力。

第二，传统的集成式增量学习算法随着学习次数的增加，集成模型的规模不断增大。针对此问题提出了一种选择性学习的集成增量学习算法，该算法在训练过程中，先用集成模型里最近使用的基分类器对新获得的数据进行增量学习，如果分类器增量学习后在此最近数据集上的分类准确率得到提升，则将增量学习后的模型代替该基分类器；若没有提升，则用前一个基分类器进行相同操作，直到遍历所有基分类器，若集成模型中所有分类器增量学习后的效果都不好，则重新训练一个基分类器加入集成模型。若分类器数量达到预定阈值，删除最旧的基分类器。学习完成后，对每个分类器用 Stacking 方法将基分类器进行组合得到集成模型。通过对比实验，证明了该增量算法规模较小，有比较高的稳定性和泛化能力。

中国知网 https://www.cnki.net

关键词：增量学习； 集成学习； 局部敏感哈希； 异构分类器集成； Stacking

中国知网 https://www.cnki.net

The Research on Ensemble Incremental Learning Classification Algorithm

ABSTRACT

With the rapid development of the Internet, mobile communications, Internet of Things and other fields, the data generated is exponentially growing, and the form of data is changing from static dataset to dynamic data stream. How to quickly and effectively acquire the implicit knowledge from data stream becomes particularly important. In real life, Non-stationary environment may change the knowledge contained in the data. Traditional batch learning methods encounter many challenges in dealing with dynamic data streams. Therefore, it is an urgent need to design an incremental model to process dynamic data stream in real time.

Incremental learning is an important research direction in the field of machine learning. It can learn new knowledge while retaining previous knowledge to a certain extent. The introduction of ensemble learning effectively improves the effect of incremental learning, but in the process of ensemble learning, in order to improve the diversity of the base classifier, the introduction of randomness in the training process of the base classifier will lead to some redundant and poor performance base classifiers in the ensemble classifier, and with the increase of the scale of the ensemble classifier, a large number of models will not only consume a lot of memory. Storage will also take more forecasting time. In this paper, an ensemble model is constructed by multiple base classifiers to incrementally learn the new data. The aim is to establish an efficient and accurate incremental learning model for predicting data stream. This paper mainly completes the following tasks:

(1) Introducing the idea of ensemble learning into incremental learning can improve the learning effect. In recent years, most of the research on ensemble incremental learning combines multiple homogeneous classifiers with weighted voting method, which does not solve the problem of stability-plasticity in incremental learning very well. An incremental learning algorithm based on heterogeneous classifier ensemble is proposed. In the stage of training, to make the ensemble model more stable, many base classifiers are trained with new data and then append into heterogeneous ensemble model. Meanwhile, Locality-Sensitive Hashing was used to save the data sketch for the nearest neighbor search of test sample. In order to adapt to the changing data, the newly acquired data will be used to updates the voting weight of the base classifier in the ensemble model. In the prediction stage, for the class label prediction of the test sample, the data similar to the test sample is found from the Local-sensitive

中国知网 https://www.cnki.net

Hashing table, this data is used as a bridge to calculate the dynamic weight of the base classifier for the test sample. Determine the class label of the test sample by combined the voting weight and dynamic weight of many base classifiers. Through comparative experiments, it is proved that the proposed algorithm has well stability and generalization ability.

(2) With the increase of learning times, the scale and complexity of the traditional ensemble incremental learning algorithm are increasing. To solve this problem, an incremental learning algorithm based on selective learning is proposed. In the training process, the new data are incrementally learned by the base classifier in the ensemble model. If the classification accuracy of the classifier on the latest data set is improved after incremental learning, the incremental learning model will replace the base classifier, or new base classifier will be trained and add to ensemble model. If the number of classifier reached predetermined threshold, remove the oldest base classifier. In the classification process, each classifier is combined with the base classifier by Stacking method to get the ensemble model. Through comparative experiments, it is proved that the incremental algorithm has small scale, high stability and generalization ability.

Keywords: incremental learning; ensemble learning; Locality-Sensitive Hashing; heterogeneous classifiers ensemble; Stacking

中国知网 https://www.cnki.net

目 录

中文摘要 I
英文摘要 III
1 绪论 1
1.1 研究背景 2
1.2 研究目的及意义 3
1.3 国内外研究现状综述 5
1.3.1 增量学习研究现状 5
1.3.2 集成学习研究现状 6
1.4 研究内容 7
1.5 论文结构 8
2 相关理论基础 9
2.1 集成学习 9
2.1.1 Bagging 11
2.1.2 Boosting 11
2.1.3 Stacking 12
2.1.4 选择性集成 14
2.1.5 组合策略 15
2.2 增量学习 16
2.2.1 单分类器增量学习 17
2.2.2 集成式增量学习 18
2.3 数据流分类 19
2.4 本章小结 20
3 基于异构分类器集成的增量学习算法 21
3.1 局部敏感哈希 22
3.2 IHCE 算法 23
3.2.1 LSH 保存数据分布梗概 23
3.2.2 更新投票权重和训练基分类器 24
3.2.3 针对待测样本计算基分类器动态权重 24
3.2.4 算法实现 24
3.2.5 算法时间复杂度 26
3.3 实验结果与分析 26

中国知网 https://www.cnki.net

3.3.1 实验数据集.....26
3.3.2 实验设置.....26
3.3.3 实验结果与分析.....27
3.4 结论.....30
4 基于选择性学习的增量学习算法..... 31
4.1 基分类器的组合.....32
4.1.1 选择性集成.....32
4.1.2 Stacking 方法.....32
4.2 IRTCE 算法.....33
4.2.1 基分类器的训练.....33
4.2.2 基分类器组合.....34
4.2.3 算法实现.....34
4.3 实验结果与分析.....35
4.3.1 实验数据集.....35
4.3.2 实验设置.....35
4.3.3 实验结果与分析.....35
4.4 本章小结.....38
5 研究结论与展望..... 40
5.1 研究结论.....40
5.2 未来展望.....40
参考文献..... 42
附录 A 科研情况..... 48
致 谢..... 49

中国知网 https://www.cnki.net

1 绪论

电子计算机作为第三次科技革命的主要产物，其广泛的应用已延伸到人们生活的方方面面，极大的影响了人们的思考方式和生活方式。电子计算机自从发明以来，人们就在探究如何让电子计算机拥有人类般的智能。Alan Mathison Turing 在 1950 年就预言了机器具有人类智能的可能性，并提出了图灵测试（The Turing test）。在 1956 年的达特茅斯会议上，人工智能即 AI（Artificial Intelligence）被正式提出，随后其子领域譬如机器学习（Machine Learning）、数据挖掘（Data Mining）、演化计算（Evolution Computation）发展迅猛。2018 年 DeepMind 公式开发的“AlphaGo Zero”真正的实现了无师自通，是人工智能发展进程中的一个里程碑。机器学习是人工智能领域一个前沿的研究分支，其研究涉及了几何、代数、泛函分析、概率统计、优化、图论、信息论、认知计算等多个学科知识。其主要是用算法在历史数据中学习，建立知识模型，用该知识模型对遇到的未知数据做出预测。其应用不仅局限于数据挖掘、模式识别、计算机视觉、智能控制等学科，甚至在经济学、管理学和历史学中也有应用。图 1.1 为机器学习系统精简示意图。

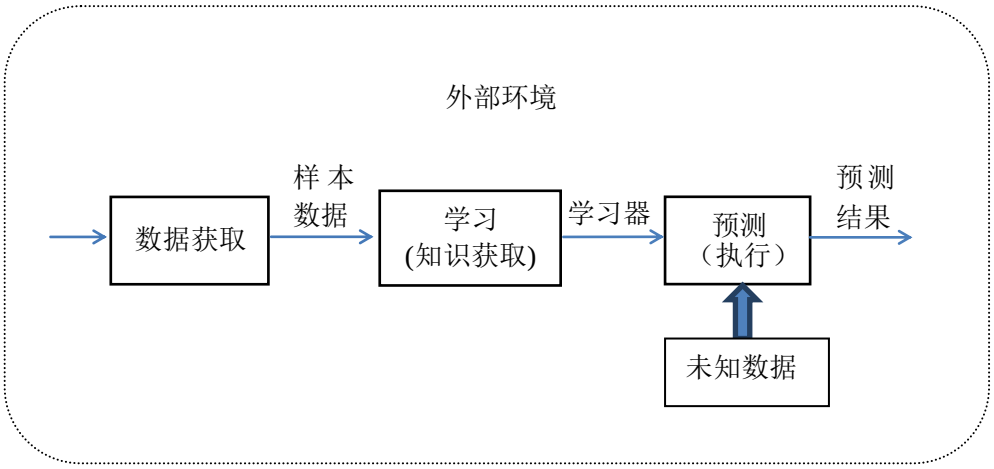

图 1.1 机器学习系统示意图

随着信息技术的发展，数据的快速增长和计算机运算能力的提升推动了机器学习的研究与发展。根据学习任务的不同，机器学习通常可以分为监督学习（Supervised Learning）、半监督学习（Semi-supervised Learning）和无监督学习（Unsupervised Learning）。本文主要讨论监督学习，它通过分析归纳已有的数据；提取数据的特征；抽象出数学模型以发现蕴含在数据中的知识；以用于对未知数据的类别做出预测。主要研究的是如何学习模型和采用什么样的模型，使得对数据的分析和预测更加准确高效，特别是如何获取实时的数据流、如何分析和处理数据并提供实时的预测系统，以更好的服务人们的生活。

中国知网 https://www.cnki.net

1.1 研究背景

目前大多数机器算法是基于静态的学习环境构建的，它们将历史数据作为一个整体进行学习，这种批量学习（Batch Learning）[1]的方式在处理数据流形式的数据集时凸显了诸多不足：例如，如果需要对一个电商平台的数据进行分析及预测，用历史数据已经训练得到了一个学习模型，当新的数据到来后，面临着两种选择：第一种，立即丢弃已经训练好的模型，将新获得的数据加入历史训练集中，重新训练新的模型。由于数据是源源不断的，这会造成模型时刻处于更新状态，而无余力去应对预测任务；第二种，为了减少集成模型重训练的次数，增大模型重新训练的时间间隔，比如将一天所累积的新数据加入历史数据集，然后重新训练。对于变化较快的数据流，第二种学习方式会造成模型没有实时更新而无法应对新的情境。批量学习只为在历史数据中尽量学习到更多的知识以获得足够的泛化能力，以应对今后的预测任务，并没有考虑到环境的变化等因素，所以现有的大多数批量学习算法都不适用于环境变化产生了新的数据流的学习。

我们当前置身于信息爆炸的时代，信息技术的高速发展，使得数据呈现指数增长。这些数据主要是以数据流的形式源源不断的产生，数据流的特征具有以下几点：

1）海量性，实时的数据流随着时间的推移源源不断地产生，除非人为干预，不然这种数据流会一直产生，从不间断。所以数据流容量是潜在海量的。如商城在线交易平台，每天产生数以亿计的交易记录，若对数据完整地存储会需要很大的时空开销。

2）有序性，数据流是以时间的先后顺序产生的，因此数据流包含了重要的时间信息，所以数据通常只能按照顺序读取与分析，大范围的随机访问是不现实的。

3）时变性，数据流可能会因为产生数据的环境发生了变化，导致数据的属性或者分布产生了改变，最终使得目标概念可能会发生改变。例如，用户兴趣变化、网络攻击等。

4）快速性，相对于传统的静态数据集，数据流每个时间段产生的数据量不是恒定的，不过从整体上看，其数据的产生速度非常快。

对于近年来物联网、云计算、互联网以及移动通信等领域高速产生和不断变化的数据，批量学习方式存在如下几个缺点：1）训练集数据需要一次性获得，对于不断产生的新数据，需要消耗大量的时间来重新训练模型。在现实生活中，网站点击量分析、个性化推荐、电力和银行等产生的数据每天都在激增，由于数据过于庞大，训练模型需要耗费很长的时间，如果当新数据到来，重新训练模型是不现实的。2）批量学习的方式不能适用于非稳定环境（Non-Stationary Environments）下发生概念漂移的数据。3）数据源源不断的产生，数据积累量变大，导致数据无

中国知网 https://www.cnki.net

法一次性载入内存，从而无法进行完整的批量学习。面对连续不断的数据流，如果每次都采用批量学习的方式，在新获得的数据后重新构建模型是不切实际的，因为数据经过一段时间的累积，数据量变得非常庞大，要在有限的时间内学习这些数据，并对未知数据做出预测会有较大的时间开销。面对这样纷至沓来的数据，只能依靠增量式学习的方法进行解决。

增量学习[2]与批量学习的不同之处在于：增量学习（Increment Learning）首先使用部分已有的数据建立初始模型，然后使用后续得到的数据对模型进行调整更新以适应数据的变化。增量学习需具备以下特点[3]：（1）在保留大多数知识的前提下重新数据中学到新知识；（2）不需要重复访问处理过的数据，已经学习的数据可以丢弃而不必存储。由于当前的数据大多呈现数据流的形式，其中数据流中可能有大量重复的数据，相对于传统的批量学习，这种学习方式有着巨大的优势：（1）数据量过大，将海量数据一次性载入内存是不现实的，保存这些数据也会有巨大的时空开销。（2）产生数据的环境是不稳定的，若数据流中的数据发生变化时，增量学习通过修改模型的参数或者结构以适应数据的动态变化，这种对模型进行修改的代价远远小于重新训练一个模型的代价。

数据流的时变性可能会导致数据流概念漂移（Concept Drift）[4][5]的发生，概念漂移是指需要预测的目标变量随着时间的推移发生了变化。在金融风险预测[6]、社交计算和传感器网络中普遍存在，一旦数据流发生变化，对于单分类器增量学习而言，需要不断的调整单分类器增量模型的结构或者参数，使得模型表现得极为不稳定，还可能发生过拟合问题。将集成学习的思想引入到增量学习之中可以提高模型的稳定性和准确率，但是也存在一些问题，比如先前学到的基模型可能因数据的变化而失去了存在的价值，冗余的分类器使得集成模型过于庞大。如何用精简的模型获得更好的学习能力？这方面的研究仍处于初级阶段。

1.2 研究意义

信息技术的发展，数据流源源不断的产生，这让传统批量学习方法面临两难的选择，新到来的数据量达到多大时才需要重新训练模型？如果过短，系统每时每刻都在重新训练模型，机器不堪重负；如果重新训练的时间节点太长，模型变得过于陈旧。如某电商推荐系统，如果更新周期过短，机器无法在有限的时间内处理完庞大的数据；周期过长，推荐的信息建立在较旧的历史数据上，导致推荐信息过时。特别是数据样本分布特征可能随时间发生变化，比如“流行”一词，以前很流行的事物，过了一段时间就变得落伍。所以如何做到模型适应数据流的变化，与时俱进？同时花费较小的代价对数据及时地学习、更新模型？有着非常深远的研究意义。基于静态数据学习方法有着很大的局限性，如何设计出高效精

中国知网 https://www.cnki.net

确的模型对数据流进行处理，从数据流中发现有价值的信息并服务于人们的日常生活成为研究的热点。基于静态环境的学习方法只是动态数据流学习的一个特殊的情况，增量学习需要考虑的因素比较多，不但是因为数据流的连续性，而且产生数据的环境也在变化，所以无论是目标变量还是特征，也许都有变化，这就导致模型更加复杂。而现实生活中，无时不刻产生的数据流包含了诸多信息，如果用这些数据对未来的变化做出预测变得极为重要,因此，增量学习的研究有着迫切的现实需求。

随着数据流取代静态数据集成为主角，使得增量学习逐渐受到研究者的重视。增量学习根据使用分类器的数量可以分为单分类器增量学习和集成式增量学习，单分类器增量学习使用的基分类算法需要有增量学习能力。通常其模型比较复杂且稳定性较差，通过多次学习后容易出现过度拟合现象。随后的研究将集成学习运用于增量学习的方式变得流行起来，通过将多个模型集成起来可以提升分类准确率和系统的稳定性，不需要基算法具有增量学习能力，通常情况下是通过若干次学习产生多个新的分类器。在预测阶段，将多个分类器根据实际情况进行结合得到集成模型。然而集成技术的应用可能使得集成模型的规模过于庞大，存储基模型会耗费大量的时间和空间。在实际预测应用中，有的分类器因为数据中隐含的知识发生了变化而过时，它们的存在不但会拖慢集成模型的预测速度，还会降低集成模型的预测准确性。

周志华教授在 2002 年研究集成学习时提出：选择一部分合适的基模型进行集成可以提升集成模型的运行速度和预测准确率。而在集成式增量学习中，基模型的数量会随着学习次数的增多而增加。随着数据流发生变化，先前训练的模型可能不再适用于当前数据，若将这些模型剔除，可以降少集成模型的运行时间。故在集成式增量学习中，将选择性集成技术应用于集成式增量学习可以提升模型的性能。本文为了用更加精简的模型获得足够好的学习效果，主要从以下两方面进行研究：（1）利用新增数据提高已有分类模型的分类器精度，为使模型更具稳定性和较好的分类准确性，采用异构的方式组建集成模型，同时采用局部敏感哈希表保存数据梗概以备待测样本近邻的查找；为了适应不断变化的数据，还会用新获得的数据更新集成模型中基分类器的投票权重；对待测样本进行类别预测时，以局部敏感哈希表中与待测样本相似的数据作为桥梁，计算基分类器针对该待测样本的动态权重，以应对数据流发生变化等情况。（2）已有的大多数集成式增量学习算法在训练阶段采用每次学习都加入一个新基分类器，这种方法虽然简单，但是模型的规模会呈直线上升。为了用更精简的模型获得较好的学习效果，本文提出，对新获得的数据首先判断集成模型中是否存在一个模型合适对当前数据进行学习，如果能找到一个这样的分类器，即直接用该基分类器进行增量学习，当

中国知网 https://www.cnki.net

集成模型中所有基分类器都不适应该数据时，才重新训练一个新分类器加入集成模型。这样对于数据流中重复的数据，只需要一个基分类器就可以完成增量学习。

1.3 研究现状综述

1.3.1 增量学习研究现状

1962 年《Science》发表了一篇关于增量学习[2]的文章，随后在五十多年的时间里，其发展已经延伸到机器学习的各个方面：监督学习、半监督学习和无监督学习等等。它主要致力于解决概念漂移问题、不平衡数据流的处理、连续属性的处理、训练窗口大小的自适应、分类器性能的评价标准和样本抽取等问题。文献[7]将概念获取算法（HMCAP）和神经网络算法（FTART）有机结合提出混合型学习模型（HLM）算法是国内较早提到增量学习的文章。国外学者对增量学习的研究要比国内更早，增量学习研究的初期多属于单分类器增量学习，有关增量学习的文章中，使用率较高的算法是决策树、贝叶斯、支持向量机和神经网络，在原算法上稍加修改即可使得算法具有增量学习能力，提出的算法主要有增量贝叶斯，增量随机梯度下降、增量式决策树和增量式 SVM 等等。

由于单分类器增量学习算法需要不断调整内部结构或参数以适应数据流的变化，所以很多时候表现的很不稳定，还很容易出现过拟合问题。集成式增量学习通过集成多个模型的结果来提升增量模型的稳定性和准确率，传统的集成方法 Bagging 和 Boosting 在增量学习中均有所拓展，SEA[8]是最早提出的基于数据块的学习算法，可以看出它是 Bagging 在增量学习中的应用。2001 年 Polikar 将 Boosting 方法应用到各数据块的学习中，提出了比较经典的集成式增量学习算法 Learn++[9]。其灵感来源于 AdaBoost 算法。为解决数据流中出现新类别时导致“outvoting”问题，在 Learn++算法的基础上提出了 Learn++.MT 算法[10]和 Learn++.NC 算法[11] Learn++.UDNC 算法[12]则考虑了不平衡数据集的情况。Learn++.SMOTE 算法[13]同时考虑到不平衡数据集和概念漂移情况。Learn++.NSE 算法[14]则主要解决非平稳环境下的概念漂移问题。2011 年 Ditzler 和 Polikar 结合半监督提出 WEA[15]算法，2013 年，两人结合 Learn++.NSE 和 Learn++.SMOTE 算法的优势提出 Learn++.CDS 算法[16]，其主要用于解决在不平衡数据集上的发生概念漂移等问题。在近几年里，文献[17]-[21]提出 Learn++算法的若干版本。

文献[22]总结了 2014 年以前提出的一些经典的集成式增量学习算法：ENN、SONG、NCL 等以及他们的改进算法，本文不再重复叙述。集成式增量学习方法通过加权组合多个不同的基模型来对数据流进行学习，它不但能保存前面学到的历史知识，而且能够很好的解决数据中数据分布发生变化等情况，比较普遍运用的方法有随机森林[22]和二部图集成[24]，文献[25]-[28]针对概念漂移问题说提出的加

中国知网 https://www.cnki.net

权方案，文献[29]对集成学习用于数据流分类的研究进行了归纳总结，分别从集成模型的架构、基分类器的投票方式、基分类器之间的关系、基分类器是否具备增量学习等方面进行了详细的分类讨论，可以发现集成式的增量学习在数据流中有着广泛的应用。文献[30]对目前存在的较高水平的增量学习算法（ISVM、IASVM、ORF、ILVQ、IELM 等）做了归纳和比较。可以看到，最近几年关于增量学习算法的研究呈现上升的趋势，但是其研究从总体上来说仍是比较欠缺的。

1.3.2 集成学习研究现状

集成学习是指在解决复杂问题时使用多个不同的基模型针对同一个问题学习构建一个集成模型，可以获得比单个模型更好的预测效果。集成学习和传统单模型学习方式不同，其主要目的是组合多个模型得到最优的集成模型以达到更高的学习能力。Salamon 和 Hanson 在 1990 年对神经网络集成进行了研究[31]，首次提出了神经网络集成的概念。L.Breiman 在重复取样技术的基础上，提出了著名的 Bagging 方法[32]，该方法对原始数据集进行有放回的重复随机采样，得到一些有差异的训练集，再用这些训练集分别训练基分类器，需要对未知样本进行预测时，所有的分类器通过投票的方式来决定未知样本的结果。另一种集成学习方法是 Boosting[33]，其思想来源于 Valiant 提出的 PAC（Probably approximately correct）模型[34]。1997 年 Freund 和 Schapire 提出的 AdaBoost（Adaptive Boosting）算法[35]是当前集成学习中最具有代表性且最流行的 Boosting 算法。近几年单纯研究集成学习的文章并不多，通常是在学习过程中的两个阶段（基分类器训练、基分类器结合）进行改进或创新。如文献[36]-[38]针对实际情况，采用集成学习的方式构建的集成模型；当前大多数的研究是将集成学习的思想用于增量学习或者数据流分类等方面。

集成学习可以获得比单个分类器更好的泛化能力，但是模型的规模较为庞大。国内外已经有许多研究尝试用选择性集成学习的方法来降低集成模型的规模，通过度量基分类器之间的多样性来剔除冗余的分类器，用当前数据集测试基分类器的分类误差，删除性能不好的基分类器。研究证明选择性集成不但可以提升集成分类器的预测性能，还可以减小存储空间和提升算法运行速度。目前选择性集成算法根据选择策略的不同可以被分为四大类：优化法、排序法、分簇法和模式挖掘法。优化法除了有代表性的基于遗产算法的 GASEN 算法[39]外，还有基于整数规划的 SDP 算法[40]和基于强化学习的 EPRL 算法[41]；分簇法一般采用聚类的方式将所有的基分类器聚为几个簇，然后从每个簇中选择一个最具代表性的基分类器。聚类算法一般采用分层聚类、K-means 算法等；如基于 FP-Tree 的快速选择性集成 CPM-EP 算法[42]这类算法的关键是模式挖掘的设计，创建一棵树保存先前学习到

中国知网 https://www.cnki.net

的关联关系，这种方法可以通过已有的模式快速地对分类器进行选择；排序法以Martinez-Munoz.G 提出的 Oriented Order 算法为代表，采用某种度量方法将基分类器进行排序，然后选择排序靠前的分类器进行集成，特点是需要的存储空间少、算法速度快。文献[43]对 2011 年前出现的选择性集成的研究进行了详细的综述，随后出现了基于多样性正规化的选择集成 DREP 算法[44]、基于选择性集成的最大化软间隔算法[45]、基于频繁模式的选择性集成算法[46]。随着增量学习研究的增多，集成式增量学习模型的规模会直线上升，所以选择性集成在数据流分类等领域也被广泛应用，文献[22]和[47]将选择性集成用于增量学习之中，以降低集成模型规模。

1.4 研究内容

增量学习在知识发现与智能化数据挖掘方面得到了广泛应用，是处理海量数据的一个重要手段。研究初期大多集中在单分类器增量学习算法之上，但其凸显出预测准确率不高且稳定性较差等问题。随后许多学者将集成学习引入增量学习，用多分类器构建集成模型。但集成模型的多个基分类器一旦训练完成，其基分类器的权重在预测不同的待测样本时是固定的。由于学习器具有偏好（bias），有些基分类器虽然在先前的训练集上分类能力好，但有可能不适应后来的数据而造成分类能力差，特别是对于数据发生分布变化或者产生概念漂移的情况。另一个问题就是，由于数据流中有非常多的相似或重复数据，这可能会造成集成学习集成模型冗余度高、预测开销大等问题，所以需要考虑如何用更小的集成模型获得足够的预测准确率。本论文研究的内容有以下两个方面：

第一，论文分析了集成模型中基分类器同构与异构的差别，根据基分类器之间应该“好而不同”的建议，选择用异构分类器的方式来组建集成增量模型，针对增量学习中数据隐含的知识可能发生变化等特点，通过多次对基模型的权重不断更新。在对未知样本的预测阶段，首先计算基分类器对待测样本周围多个近邻点的分类准确率，以此来度量该基分类器和待测样本的适应性，从而使各个基分类器获得针对待测样本的动态权重，通过双权重共同决定该基分类器的投票权重。这种方式使异构分类器模型能够适应数据流的变化，从而得到了较好的预测效果。

第二，集成式增量学习随着学习次数的增加，如果单纯的经过每次训练得到一个基分类器加入集成模型，那么集成模型的规模会越来越庞大而不实用。通过分析发现，多数情况下，数据流中相似或重复的数据所占比重非常大，造成了训练的很多的基分类器之间相似度比较高。因此，在训练阶段避免重复训练基分类器是十分必要的。如果对于一个新数据块，分析发现该数据块与集成模型中某个基分类器相适应，则直接用这个分类器对该数据块进行增量学习，而不必添加新

中国知网 https://www.cnki.net

的分类器。实验发现经过多次学习后，训练的基分类器数量不再呈现直线上升的趋势，而是到达某个值后上升缓慢。这种选择性学习的方式训练的集成模型的准确性也和多数集成式增量学习算法相近，但其集成模型的规模大幅度降低。

1.5 论文结构

本文在充分研究了集成学习和增量学习的基础之后，将集成学习的思想引入到增量学习之中，以实现对数据流形式的数据进行学习与分类。为了提升对数据流的学习能力，通过集成多个异构模型的方式来学习数据块；为提升模型的分类精度，在学习过程中对基分类器权重做出调整；在预测阶段，加入了能度量待测样本与各个弱分类器适应性的动态权重；通过双权重共同决定该弱分类器的投票权重，以适应数据流发生变化等情况。针对集成模型会随着学习次数增多变得越来越庞大等问题，在保证集成模型的精度的情况下降低模型的规模，采用了一种轮转式的结构来组织基分类器，当新数据到来时，选择某个基分类器对新数据块进行增量学习的方式，从而大幅度压缩集成模型的规模。根据主要的研究内容，本论文分为五章，组织结构如下：

第一章叙述了课题的研究背景、目的和意义，主要阐述了增量学习和集成学习的研究现状，针对当前的研究现状，简要指出本文的创新点和研究内容。

第二章对本文研究的内容所涉及的相关知识进行了简要的介绍，主要阐述了增量学习、集成学习和数据流分类的相关知识。

第三章针对现阶段集成式增量学习算法大多没有对增量式算法中的稳定-可塑性难题提出较好解决方法的情况下，提出了一种异构分类器集成的增量学习算法，该算法在基分类的训练阶段用多种分类算法训练多个基分类器，并实时更新基分类器权重；采用局部敏感哈希表剔除数据流中重复数据；对待测样本进行类别预测时，以局部敏感哈希表中与待测样本相似的数据作为桥梁，计算基分类器针对该待测样本的动态权重，结合基分类器的双权重判定待测样本所属类别。

第四章针对集成式增量学习集成模型规模会随着学习次数的增加，规模变大越来越庞大的问题，提出了一种轮转式的集成增量学习算法，该算法在训练过程中，用集成模型中找到的某个合适的基分类器对新获得的数据进行增量学习，如果集成模型中找不到合适的分类器时才加入新训练的基模型。实验发现这种方法能够在损失较小的精度下大幅度降低集成模型的规模。

第五章对本文的工作进行了总结并指出其不足，对未来需要研究的问题进行展望。

中国知网 https://www.cnki.net

2 相关理论基础

分类是模式识别、机器学习和数据挖掘等领域一个重要的研究方向。其思想是通过对已有的数据进行学习，然后利用所获得的规律（分类器）对未知类别的数据进行类别预测。其形式化定义为：给定一个训练数据集$D=\{(X_i,y_i)|X_i\in \mathrm{X}, y_i\in Y, i\in N\}$，$X_i$表示第$i$个样本的属性，y为对应的类别，利用学习算法$F$对$D$中的样本进行训练，得到一种映射结果$\mathrm{y}=F(D)$。一个好的分类器不仅仅能够对历史数据有很好的分类效果，还要对未见过的数据有很好的分类能力，即泛化能力。分类问题如图像识别、异常点检测、垃圾邮件过滤等问题被学术界广泛关注，本文主要研究不断累积的数据的分类问题。

2.1 集成学习

在统计学中，将多个观测量取平均值可以减少单个观测量随机波动所产生的影响，从而使得估计量更加的稳定和可靠。集成学习的思想是对同一问题使用若干个学习器进行学习，然后按照一定的策略将多个不同的学习结果进行整合，利用学习器之间的互补性，以获得比单个学习器更好的泛化能力，其思想来源于Valiant 提出的 PAC(Probably approximately correct)学习模型[34]。通常构造多个比随机猜测好的模型要比构造一个高精度模型容易得多。Valiant 和 Kearns 在 1998 年证明了弱学习算法与强学习算法是等价的，这成为集成学习的起源，它通过将多个学习器对同一个问题进行学习，将各个学习器的结果用合适的方式结合，这种方法显著提高了学习系统的泛化能力。

在二分类问题中 y 为真实类标签，若基分类器h_i的错误率为ε

$$P\left(\mathrm{h}_i(\mathrm{x}) \neq \mathrm{y}_i\right) = \varepsilon \qquad \text{（式 2.1）}$$

如果通过简单的多数投票结合 T个基分类器，集成分类正确率为：

$$\mathrm{H}(x) = \mathrm{sign}\left(\sum_{i=1}^{T} \mathrm{h}_i(x)\right) \qquad \text{（式2.2）}$$

假设每个基分类器错误率相互独立，则集成错误率为：

$$\begin{aligned} P(\mathrm{H}(x) \neq y) &= \sum_{k=0}^{T/2} \binom{T}{k} (1-\varepsilon)^k \varepsilon^{T-\varepsilon} \\ &\leq \exp\left(-\tfrac{1}{2} T(1-2\varepsilon)^2\right) \qquad \text{（式2.3）} \end{aligned}$$

由以上公式可知：随基分类器数量的增加，集成分类器的错误率将趋近于零。

中国知网 https://www.cnki.net

集成学习主要分为基分类器的训练阶段和基分类器的组合两个阶段。其中训练阶段主要目的是训练多个有差异的基分类器，组合阶段主要是采用更有效的结合方式将多分类器融合成一个强分类器，使其拥有更好的泛化能力。集成学习示意图 2.1 所示：

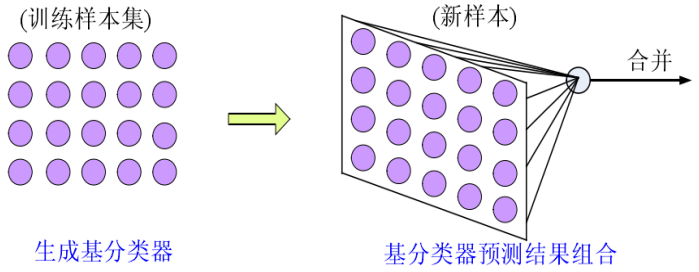

图 2.1 集成学习示意图

有一个关键的假设：基分类器的误差应相互独立。而在现实任务中，个体分类器是针对同一个问题学习得到的，所以不太可能相互独立。在实际问题中通常无法做到基分类器之间相互独立，但可以通过引入扰动等技术使得基分类器之间的差异比较大。同时，基分类器的准确性和多样性两者之间存在冲突，当每个基分类器的准确率都比较高时，其基分类器之间的多样性就比较小。集成学习的研究主要就是如何训练产生和结合好而不同的分类器。

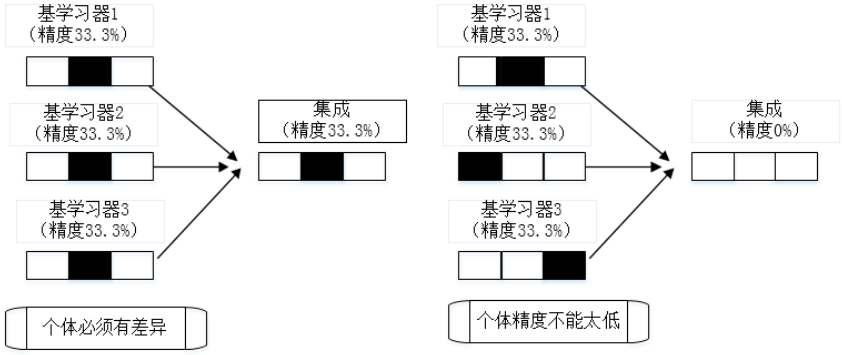

图 2.2 基分类器应“好而不同”

根据基分类器之间是否存在依赖关系可以将集成学习大体分为两类：（1）第一类以 Bagging 方法为代表，主要通过对样本的随机选择来组建有差别的训练集，通过训练数据的不同来保证基分类器之间存在差异，由于生成的基分类器之间没有依赖关系，所以训练基分类器的过程可以并行实现；（2）基分类器之间存在依赖关系，这类以 Boosting 方法为代表，先用训练集训练一个基分类器，而后分析该基分类存在的问题，后续训练的分类器尽量是用来弥补前面分类器的缺陷，后续基分类器的训练依赖于前面的基分类器的分类器效果。另一种称为 Stacking 的基分类器组合方法，它与前面两种方法的不同之处在于：在基分类器的组合过程中用一个元算法来学习如何将基分类器进行结合，才能达到更好的泛化能力。

中国知网 https://www.cnki.net

2.1.1 Bagging

Bagging 方法[32]是 Breiman 在 1996 年提出的，是最具代表性的并行式集成学习方法。为了克服训练样本集中样本是有限的问题，Bagging 采用 Boostrapping 放回式抽样的方法，从原始训练集中有放回的随机抽样，构造若干个与原始训练集数量相同的训练集。然后在每个训练集上训练基分类器，预测阶段采用合适的方法将基分类器的预测结果进行综合。

Bagging 方法：

输入：训练集$D = \{(x_1, y_1), (x_2, y_2), ... (x_m, y_m)\}$;基分类算法$A$；训练次数$T$

过程：For t=1，2，…T do

从训练集中有放回的取出 m 个训练样本得到多个训练集D_{bs}，用每个D_{bs}分别训练类器基分类器：

$$h_t = A(D, D_{bs}) \quad (式 2.4)$$

End For

输出：$H_{(x)} = \arg\max_{y \in Y} \sum_{t=1}^{T} I(h_t(x)=y)$

Bagging 算法可以有效提高模型的泛化能力与稳定性。基于这一点可知，其基分类算法一般选择不稳定算法，如决策树或神经网络等算法，需要基分类器的错误率不要过高。Bagging 方法在训练基分类器的过程中通常有 63.2%的数据会被选入训练集，剩下的数据可以用作测试集以测试模型的性能。由于 Bagging 方法的基分类器之间没有依赖关系，所以训练阶段可以采用并行的方式生成基分类器，可以节约训练时间。也正是因为这样，算法训练的每个基分类器都独立于其他分类器，若要提高准确率，需要引入大量的分类器。

2.1.2 Boosting

Boosting 方法[33]是一类增强算法，是 Schapire 等人在 1990 年证明弱学习算法等价于强学习算法的基础上发展而来，这种方法所产生的后续分类器是总结了先前训练分类器的误差而训练得来的，使得基分类器之间呈互补状态，这种方法比 Bagging 方法更加聪明和有效。1997 年 Freund 和 Schapire 提出的 AdaBoost(Adaptive Boosting)算法[35]是当前集成学习中最具有代表性且最流行的 Boosting 算法，AdaBoost 算法初始阶段先对每个训练样本赋予相同的权重，每轮迭代训练得到若干个基分类器，对于能被该轮基分类器正确分类的样本，降低他们的权重，增加被错误分类样本的权重，使后面训练的基分类器把分类工作的重心集中在那些较难分的样本上，使得训练的各轮分类器之间形成互补。其中，每一轮基分类器的投票权重都来源于该基分类器对训练集的分类准确率。将若干次学习所获得的基

中国知网 https://www.cnki.net

分类器通过加权组合得到最终的强分类器。

AdaBoost 算法流程：

输入：训练集 $D=\{(x_1,y_1),(x_2,y_2),\ldots(x_N,y_N)\}$，其中 $x_i \in \chi \subseteq \Re^n$，$y_i \in Y=\{-1,+1\}$；迭代次数 T；弱学习算法；测试数据 $(x_{test},\ )$。

输出：带双权重的分类器集合 $f(x)$

训练阶段：

步骤 1 初始化每个样本权重

$$D_1=(w_{11},\ldots w_{1i},\ldots w_{1N}),\ w_{1i}=1/N,\ i=1,2,\ \ldots,N$$

步骤 2 对 m=1 to T do

（a）用具有权重分布 D_m 的训练集学习得到弱分类器

$$h_m(x):\ \chi \rightarrow \{-1,+1\}$$

（b）计算 $h_m(x)$ 在训练集上的分类误差

$$e_m=P(h_m(x_i) \neq y_i)=\sum_{i=1}^{N} w_{mi} I(h_m(x_i) \neq y_i) \qquad \text{（式 2.5）}$$

（c）计算 h_m 的静态权重

$$\alpha_m=\frac{1}{2}\ln\frac{1-e_m}{e_m} \qquad \text{（式 2.6）}$$

（d）更新训练集权重分布

$$D_{m+1}=(w_{m+1,1},\ldots w_{m+1,i},\ldots w_{m+1,N})$$

$$w_{m+1,i}=\begin{cases}\dfrac{w_{mi}}{Z_m}e^{-\alpha_m}, & h_m(x_i)=y_i\\[2ex] \dfrac{w_{mi}}{Z_m}e^{\alpha_m}, & h_m(x_i)\neq y_i\end{cases} \qquad \text{（式 2.7）}$$

其中，$Z_m=\sum_{i=1}^{N} w_{mi}\exp(-\alpha_m y_i h_m(x_i))$，$Z_m$ 是规范因子

步骤 3 得到 T 个弱分类器 $H=\{h_1,h_2,\ldots h_T\}$

得到对于待测样本 $(x_{test},\ )$ 的线性组合分类器

$$f(x)=\sum_{m=1}^{T}\alpha_m h_m(x)*\beta_m \qquad \text{（式 2.8）}$$

2.1.3 Stacking

当训练数据充裕时，可以考虑用更加“聪明”的组合方法：Stacking 方法，它的结构通常有 2 层。用训练集训练多个基学习器作为 0 层，1 层学习是将 0 层学习器的输出结果作为训练数据，训练一个元学习器，将多个基学习器的输出结果进行结合。模型如图 2.3 所示：

中国知网 https://www.cnki.net

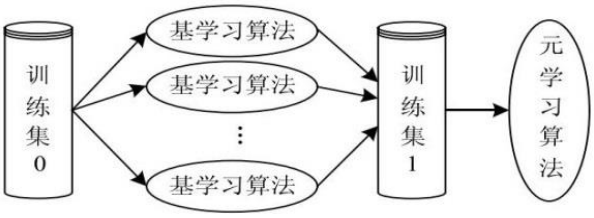

图 2.3 Stacking 模型示意图

其中 0 层模型的输出可以是类标签，也可以是类概率分布[49]。类概率分布和类标签相比，不但可以反映分类器将数据判定为那个类，还会告诉其属于该类的概率 $P(C_j \mid x)$。单个基分类器 h_i 对样本 x 预测结果是一个 c 维向量，所有基分类器对 x 进行预测会得到一个概率矩阵：

$$DP(x) = \begin{bmatrix} h_1^1(x) & h_1^2(x) & \dots & h_1^c(x) \\ h_2^1(x) & h_2^2(x) & \cdots & h_1^1(x) \\ \vdots & \vdots & \vdots & \vdots \\ h_n^1(x) & h_n^2(x) & \cdots & h_n^c(x) \end{bmatrix} \quad (式2.9)$$

其中，矩阵中的 i 行 j 列指基分类器 h_i 预测样本 x 属于第 j 类的概率值。将 n 个基分类器的输出结果与类标签 y 结合得到 1 层学习器的训练数据 $(x^{meta}, y) = (DP(x), y)$。一般情况下，训练数据较多时用 Stacking 方法来组合基分类器比其他方式更好。

Stacking 算法流程：

输入： 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots (x_m, y_m)\}$；基学习算法：$\{A_1, A_2, \dots A_T\}$；元学习算法 A。

过程：

步骤 1： 用不同的基学习算法分别训练 0 层学习器：

For t=1，2，…T do

$$h_t = A_t(D) \quad (式2.10)$$

End For

步骤 2： 用 h_t 预测训练集 D 数据得到元学习算法的训练集：

$D' = \varnothing$

For i=1，2，…m do

For t=1，2，…T do

$$Z_{it} = h_t(x_i) \quad (式2.11)$$

End For

$$D' = D' \cup ((Z_{i1}, Z_{i2}, \dots Z_{iT}), y_i) \quad (式2.12)$$

End For

步骤 3： 训练 1 层学习器：

$$h' = A(D') \quad (式2.13)$$

输出：

$$H(x) = h'(h_1(x), h_2(x), \dots h_T(x)) \quad (式2.14)$$

中国知网 https://www.cnki.net

2.1.4 选择性集成

集成学习在训练基分类器时为了使基分类器之间的差异度足够大，会使用一些扰动技术，这可能会导致生成一些冗余的、性能不好的基分类器，这些多余的基分类器可能会对集成分类器的性能造成不好的影响。研究人员发现，在基分类器训练和组合过程中间加入一个选择基分类器的过程（剔除集成分类器之中冗余和分类效果差的分类器）可以提升集成模型的性能。选择基分类器过程主要有 2 点：（1）剔除一些分类效果相对不佳的基分类器，以提升模型的预测精度；（2）剔除高度重复的基分类器，以提高模型的运行效率。

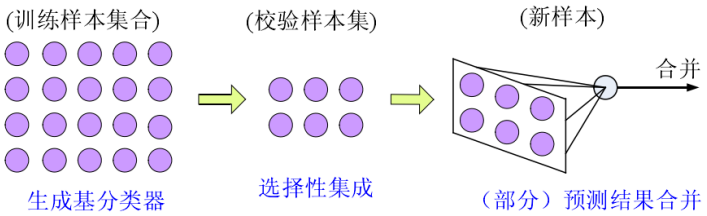

图 2.4 选择性集成示意图

集成分类器 $H(X)=\{h_1(X_1),h_2(X_2),...h_T(X_T)\}$ 是在数据集 $D=\{(X_1,y_1),(X_2,y_2),...(X_n,y_n)\}$ 上学习得到的，$y_i\in\{1,2,...k\}$ 为训练样本的真实类别，基分类器 h_i 的权重为 w_i，设 $\hat{y}_j$ 为基分类器 h_j 的预测结果 $\hat{y}_j=\left[\hat{y}_{j1},\hat{y}_{j2},...\hat{y}_{jn}\right]$，则 h_j 在数据集 D 上的分类错误率为：

$$E_j=\frac{1}{n}\sum_{i=1}^{n}L(\hat{y}_{ji},y_i) \qquad (式\ 2.15)$$

其中 $L(g)$ 为损失函数，分类器 $H(X)$ 在数据集 D 上的集成错误率为：

$$E_H=\frac{1}{n}\sum_{i=1}^{n}L(H_{ji},y_i) \qquad (式2.16)$$

其中 $H_{ji}=\arg\max(w_c),w_c=\sum_{j=1}^{T}\{\mathrm{sign}(h_{ji}=c)w_i\},c=\{1,2,...k\}$。新的集成分类器 $\hat{H}(X)$ 是从 $H(X)$ 中剔除 t 个基分类器的集合，其在数据集 D 上的分类错误率为：

$$E_{\hat{H}}=\frac{1}{n}\sum_{i=1}^{n}L(\hat{H}_{ji},y_i) \qquad (式2.17)$$

其中 $\hat{H}_{ji}=\arg\max(\hat{w}_c),\hat{w}_c=\sum_{j=1}^{T}\{\mathrm{sign}(h_{ji}=c)w_i-\mathrm{sign}(h_{ti}=c)w_t\},c=\{1,2,...k\}$，

$$E_H-E_{\hat{H}}=\frac{1}{n}\sum_{i=1}^{n}\left\{L\left(H_{ji},y_i\right)-L\left(\hat{H}_{ji},y_i\right)\right\}>0 \qquad (式2.18)$$

中国知网 https://www.cnki.net

由式 2.18 可知，剔除一些基学习器可以提升集成模型的分类准确率。根据图 2.2 分类器集成的描述可知，要想获得好的集成效果，不但需要基分类器本身具备较好的预测准确率，还必须基分类器之间的差异性比较大。选择性集成学习是一种从集成模型中选择子集以产生更强的泛化能力的技术。如果对一个有 L 个基分类器的集成模型用排列组合的方法，那么有 2^L-1 个非空集合，显然采取穷举法对于稍大的规模不现实的。

可根据选择基分类器的时机将选择性集成分为以下两种：（1）在训练样本上或校验集上选择较性能好的分类器进行结合，这种可以叫做静态分类器选择集成。基分类器不会随待测样本的不同而变化。（2）动态选择性集成，根据待测样本的特征动态地选择合适的分类器进行结合，这种方法可能针对不同待测样本，选择的基分类器是不同的，最具有代表性的是 GASEN 算法[50]和 DCS-LA 算法[51]。目前在批量学习之中，大多数的选择性集成方法属于静态选择性集成。由于数据流中数据的分布变化较大，用动态选择方法针对每个待测样本选出一组基分类器组合效果更好，但会花费较多的时间，如基于 KNN 的动态分类器选择算法[71]。若按照选择的策略可将选择性集成分为四类：分簇法、排名法[52]、迭代优化法[50]和模式挖掘法[47]。近几年研究主要集中在迭代优化法[53]，如文献[54]采用启发式选择方法从分层的基分类器中选择分类器使得结果更优。

随着增量学习研究的发展，为了控制增量学习模型的规模，选择性集成作为一项重要的技术被应用于集成式增量学习之中。主要有两种使用方法，第一种是采用对先前学到的知识进行遗忘，另外一种是选择可能对待测样本预测效果好的进行集成。

2.1.5 组合策略

假定集成模型中有 T 个基学习器 $H=\left(h_1, h_2, \ldots h_T\right)$，其中 h_i 在数据 x 上的输出为 $h_i(x)$，将基分类器结合的主要方式有以下几种：

- 简单平均法

$$H(x)=\frac{1}{T}\sum_{i=1}^{T} h_i(x) \qquad \text{（式 2.19）}$$

- 加权平均法

$$H(x)=\sum_{i=1}^{T} w_i h_i(x) \qquad \text{（式 2.20）}$$

其中 w_i 是基学习器 h_i 的权重，通常 $w_i \geq 0,\ \sum_{i=1}^{T} w_i = 1$。

中国知网 https://www.cnki.net

对于分类问题，集成分类器中基分类器h_i将样本 x 标准为$\{c_1, c_2, ...c_N\}$，集成分类器通常采用以下几种方式结合以得到最终类别：

- 加权投票法

$$H(x) = C_{\arg\max_j \sum_{i=1}^{T} w_i h_i^j(x)} \quad (式 2.21)$$

其中w_i为基分类器h_i的权重

- 相对多数投票法

$$H(x) = C_{\arg\max_j \sum_{i=1}^{T} h_i^j(x)} \quad (式 2.22)$$

- 绝对多数投票法

$$H(x) = \begin{cases} c_j, & if \ \sum_{i=1}^{T} h_i^j(x) > 0.5 \sum_{k=1}^{N} \sum_{i=1}^{T} h_i^k(x); \\ reject, & \text{otherwise} \end{cases} \quad (式 2.23)$$

标记为得票大于 0.5 的类别，否则拒绝标记。

在文献[29]中总结了近几年出现的比较有代表性组合策略，这里不再进行阐述，图 2.5 是比较常见的结合方案。

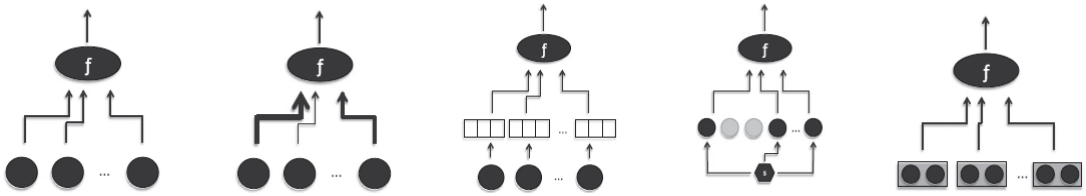

(a)多数投票 (b)加权投票 (c)排序 (d)选择投票 (e)相关性投票

图 2.5 多种不同集成策略[Gomes 2017]

2.2 增量学习

随着信息技术的发展，各领域产生的数据呈现指数增长。数据以动态数据流的形式不断的产生，想要一次性获得全部的训练数据是不可能的，例如医疗病例或 Web 日志。另一方面，数据随着时间的推移其分布或隐含的概念可能发生了变化，例如信用卡交易记录、移动数据和股票交易记录等。不同于传统的数据集，数据流具有实时、动态变化和连续性等特征，将传统的批量学习方法用到流式数据的处理中，很多时候不能达到理想的效果。一方面是因为产生数据流的时间跨度很大，产生数据的过程中环境可能变化，在先前数据上训练的模型可能不太适用于发生变化后的数据。另一方面，当获得新数据后，批量学习需要丢弃训练好的模型，将新数据纳入历史训练集中，从头开始训练新的模型。例如在电商平台上做个性化推荐系统，由于数据非常大，丢弃模型重新训练需要花费非常长的时间，并且什么时候进行模型的再训练是个很难的选择。如何提取海量数据流中蕴

中国知网 https://www.cnki.net

含的知识以更好的服务人们的生活，因此设计一个能高效处理数据流的模型变得迫在眉睫。与传统机器学习中静态学习不同，为了针对数据流实时变化、数据量未知等特点，增量模型往往需要考虑的更多，其模型更加复杂。

增量学习与人脑学习非常相似，它可以在保留以前学到知识情况下不断的学习新的知识。在数据流中，由于新产生的数据相对于原累积的数据量来说很少，批量学习前后所训练的模型可能没有发生多大的变化，但是消耗了非常多的时间。增量学习是用新数据对原模型进行微调，以达到与批量学习相似的学习结果。在增量学习中，对于数据流 $\{D_1, D_2, \ldots D_t, \ldots\}$，其中 $D_t = \{(\mathrm{X}_t^1, y_t^1), (\mathrm{X}_t^2, y_t^2), \ldots (\mathrm{X}_t^n, y_t^n)\}$ 为 t 时刻得到的数据集，X_t^i 为 D_t 中第 i 条数据向量、y_t^i 为该条数据对应的目标值。每个 t, 增量学习算法用 D_t 更新模型得到：

$$\mathrm{H}_t = \arg\min_{f \in \Re} \mathrm{E}_{(\mathrm{X}, y) \in p_t(\mathrm{X}, y)} \{L(f(\mathrm{X}), y\} \qquad \text{(式2.24)}$$

其中 $\Re$ 为模型假设空间、$p_t(\mathrm{X}, y)$ 为 t 时刻数据的联合概率分布、$L(g)$ 为损失函数。用 κ_t 表示模型从 D_t 学到的知识，通常情况下各 κ_t 很不一样，如下图 2.6 所示, 其中 D_t, D_{t-1} 为两个 t-1 时刻和 t 时刻获得的数据集，虚线为潜在决策分界线, D 是数据集合并后的数据集。增量学习即是分别对 D_t, D_{t-1} 进行学习，得到 D 所包含的分界线，如下图 2.6 所示：

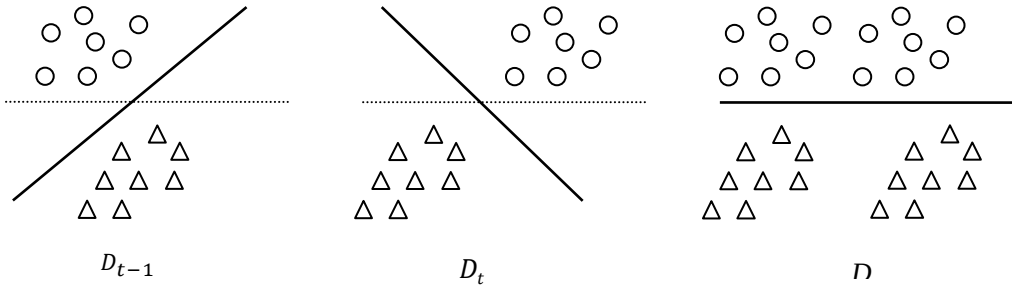

图 2.6 增量学习模型

2.2.1 单分类器增量学习

根据使用分类器的数量可将增量学习分为单分类器增量学习和集成式增量学习，单分类器增量学习指在学习过程中至始至终只用一个模型，如图 2.7 所示。单分类器增量模型根据新获得的数据调整模型的参数或内部结构，以适应训练数据的动态变化。它的主要优点是分类模型适应性好，规模小效率高。其缺点是学习次数增多可能产生过拟合问题，且需要基模型具备增量学习能力。

单分类器增量学习以快速决策树（Very Fast Decision Tree, VFDT）算法[48]为代表，后续也出现了许多 VFDT 的改进算法。虽然这些算法仍有许多的不足之处，但它使得数据流分类逐渐成为学术界研究的前沿与热点问题。

中国知网 https://www.cnki.net

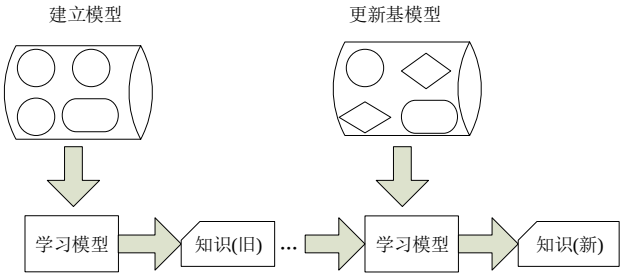

图 2.7 单分类器模型

由于单分类器增量学习模型具有不稳定性，使得它容易受到噪声的影响，而且随着学习次数的增加容易出现过拟合问题。根据这些不足，研究者尝试将集成学习引入到增量学习之中，构建集成多个分类器的增量学习模型。

2.2.2 集成式增量学习

集成增量学习是使用多个模型对训练数据进行学习。以 Learn++算法[9]为代表，对基算法是否具备增量学习能力没有要求，还能使用同构或异构等更加灵活的组合方式。

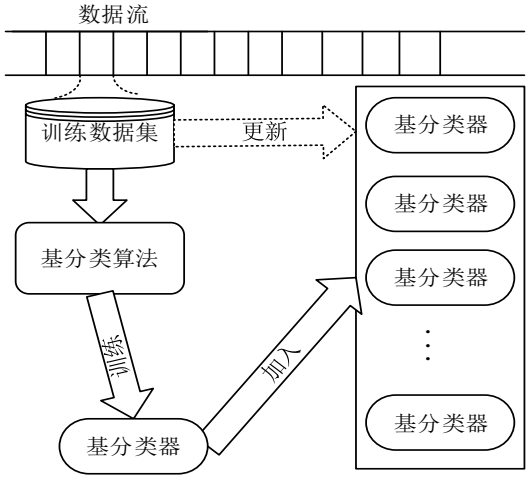

图 2.8 集成式增量学习模型示意图

如图 2.8 所示，首先将数据流根据时间分块，将一段时间内的产生的数据块作为训练数据集训练一个基分类器，将基分类器加入到集成模型中，可以根据新数据对先前训练的基分类器进行更新，也可以是不对它们做任何操作。Street 提出的 SEA 算法[8]使用多个基分类器用于数据流分类。集成式增量学习对每个数据块的训练过程和批处理方式一样简单，与单分类器增量学习算法相比，不但有较强的抗干扰能力，通常情况下分类准确率也单分类器增量模型高。

按是否控制集成模型的规模可将集成式增量学习分为两类。第一类，集成模型的规模随着学习次数的增加而增长，用新获得的数据，训练一个基分类器加入到集成模型中，如 Learn++算法[9]，这种方法在学习新知识的同时，可以很好的保

中国知网 https://www.cnki.net

留已经学习到的知识。在实际问题中，这种方法可能导致模型过于庞大而不实用。第二类是规模固定式增量学习模型，集成模型的规模不随学习次数的增加而增大，如 SEA 算法[8]，它采用启发式替代分类器的方法，将新训练的分类器代替相对旧的分类器，可以将集成模型的规模限定在一个预设的值，但是有可能造成“知识的遗忘”。

2.3 数据流分类

当前的数据大多是非实时、以静态的方式存储于数据库中。近些年随着信息技术的发展，在非稳定环境中，数据产生和收集会随着时间的变化而实时的变化，图 2.9 展示了 3 个类别的数据随着时间的推移，类别动态变化的情况。如何对数据流进行挖掘是当前研究的热点和难点。因为传统的分类模型是在静态数据集上训练得到，没有考虑到数据分布变化等因素，故模型不能实时更新以满足数据流的分类。即使对模型进行更新，重构模型会耗费大量的时间，导致等待的时间过长。与传统的数据集分类相比，数据流固有的性质使得数据流的分类需要考虑的因素更多，分类模型更复杂。

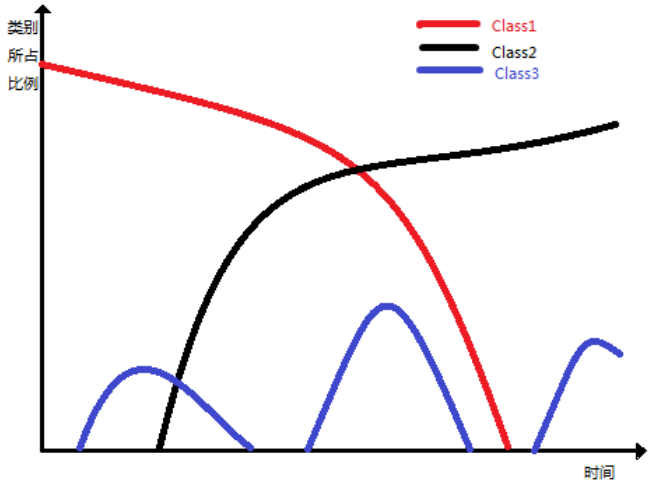

图 2.9 渐变式类别演化示意图

由于数据流的连续性，系统无法获得完整的训练集，也无法将全部的数据读入内存来训练模型。一般对数据流采用加时间窗的方式将其转化为数据集，然后用传统的静态分类模型进行处理。近年来，研究者发现数据流中数据的分布可能会随着时间的推移而改变，并将称为概念漂移现象。当概念漂移发生后，之前训练的模型变得不再适用于当前的数据。所以，如何监测概念是否产生漂移变得至关重要，但由于概念漂移产生的是随着环境的变化而变化的，原因非常多，所以至今都无法准确找出其中的规律。为克服数据流发生概念漂移的问题，很多方法都是通过加入概念漂移检测模块来实现的，一旦检测到概念漂移发生，就重新训练新的分类器等。例如 Hulten 等人在 2001 年提出的 CVFDT 算法[55]是在 VFDT 算

中国知网 https://www.cnki.net

法[48]的基础上改进而来，当检查到概念漂移发生时，用所新构建的子树替换原有的子树。在应对数据流分类中的概念漂移问题，Spinosa 所提出的在线概念漂移检测算法（OLINDDA）[56]使用聚类的方式把数据流中的数据聚为多个簇，以判定概念漂移是否发生。由于集成模型先前训练的分类模型很可能在发生概念漂移后完全失效，据此文献[58]提出可以根据模型的预测准确率急速下降作为概念漂移的依据。也通过概率论中的“3σ”法则或信息熵[57]等方法进行判定。

2.4 本章小结

本章介绍了增量学习、集成学习和数据流分类的基本知识。重点阐述集成学习中的基分类器的生成方法、基分类器的组合策略。介绍了增量学习中的单分类器增量模型和集成式增量学习模型。最后，总结了将集成学习和增量学习用于对数据流分类的一些基本情况。

中国知网 https://www.cnki.net

3 基于异构分类器集成的增量学习算法

近年来物联网、社交媒体、互联网以及移动通信等领域高速发展，数据流逐渐成为数据分析与挖掘的主角，其主要特点有无限性、实时性、易失性与动态变化性[59]。增量学习可以很好的应对数据流的处理，增量学习与人脑学习相似，是指在保留以前学到的知识的情况下不断学习来自环境的新知识。在学习过程中，由于新增加的数据相对于原累积的数据来说较少，可以用新数据对原模型进行微调以获得和批量学习相似的效果。

然而设计增量学习算法必定会面对稳定-可塑性难题[60]：稳定性是指模型必须要保存已经学过的知识，意味着模型的参数和结构不能改变；而可塑性是指为了学习新知识需要对模型的参数与结构进行调整。增量学习根据所用分类器的多少可以分为单分类器增量学习和集成式增量学习。单分类器增量学习指在学习过程中只用一个模型，模型会根据新样本调整其内部结构或者参数以适应数据的变化，具有很好的可塑性，但稳定性不高。有代表性的单分类器模型有 Hoeffding 树[61]、在线被动攻击算法[62]等，这需要所使用的基分类器本身具备增量学习能力。经大量实验表明：集成学习可以提高增量学习算法的稳定性和预测准确率[63]，集成式增量学习以 Learn++算法[8]、SEA 算法[7]为代表，使用多个分类器对数据进行增量学习，对所用的分类器是否具备增量学习能力没有要求，这种方法具有很好的稳定性，但其可塑性低，难以应对数据产生突变或者渐变等情况。文献[64]、[65]对当前流行的多种增量学习算法进行了比较和归纳，可以看出近几年提出的集成式增量学习算法如 wESVM[66]、Learn++.CDS[67]、OAUE[68]、WEOB[69]等大多是集成多个同质分类器，采用加权投票的方式对分类器进行结合。为应对集成模型可塑性差的问题，多数算法采用动态权重的方式对分类器进行结合，如文献[70]-[74]在计算动态权重过程中，查找待测样本的近邻时会计算整个数据集中的数据与待测样本的距离，但这样的方式极为耗时。尤其对于数据流，大量数据的存储与计算将会产生巨大的时空开销。

针对以往集成式增量学习中没有很好的解决稳定-可塑性问题和计算动态权重耗时问题，本文提出了一种异构分类器集成的增量学习算法(Incremental Learning Algorithm based on Heterogeneous Classifier Ensemble，IHCE)，在保证算法稳定性的前提下，兼顾算法对动态数据的适应性，获得快速而准确的增量学习模型。采用局部敏感哈希（Locality-Sensitive Hashing，LSH）来保存数据分布的梗概，用异构的分类器集成模型对不断变化的数据流进行增量学习。在预测阶段，根据待测样本与基分类器的适应性，调整基分类器的权重，以应对数据发生变化。

中国知网 https://www.cnki.net

3.1 局部敏感哈希

对于海量高维的数据流，数据流中有很多近似重复记录，可以采用将相似度很高的数据进行剔除，压缩数据得到数据流分布的梗概。以往的算法查找待测样本的近邻多是采用直接计算每个训练样本与待测样本间的欧氏距离[63]，这种方法会花费大量的时间，可以采用类似索引技术来加快查找过程。在提出的 IHCE 算法中，采用 LSH[74]的方式来剔除数据流中近似重复数据和查找待测样本的近邻。LSH 是一种高维空间最近邻搜索算法，其基本思想是：通过 Hash 函数把数据从高维空间映射到低维空间中，使得高维空间的相似数据在低维空间相似概率很高；而在高维空间不相似的数据在低维空间相似概率很低，其形式化定义如下：

定义 1（局部敏感哈希函数簇）对于 Hash 函数簇 H 中每个函数 h，如果任意两点 p, q 满足以下条件，则认为 H 是$(dist_1, dist_2, P_1, P_2)$-sensitive 的：

(1) 若$d(p,q) \le \mathrm{dist}_1$，则$\Pr_H[h(p) = h(q)] \ge P_1$.

(2) 若$d(p,q) \ge \mathrm{dist}_2$，则$\Pr_H[h(p) = h(q)] \le P_2$.

其中$\mathrm{dist}_1 < \mathrm{dist}_2, 1 \ge P_1 > P_2 \ge 0$，$d(p,q)$为 p, q 两点的距离，$\Pr_H[\cdot]$表示 p, q 两点的哈希值相同的概率。条件（1）保证两个相似点以高概率被映射进同一个哈希桶；（2）保证两个不相似的点以低概率映射进同一个哈希桶。LSH 表结构如图 3.1。

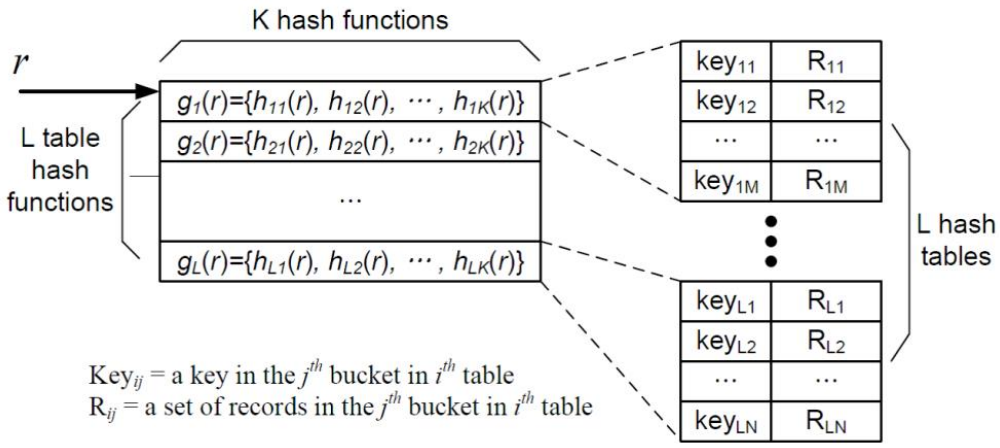

图 3.1 LSH 表结构

局部敏感哈希常用的距离度量有汉明距离、欧式距离和余弦距离，通常较高维的数据采用余弦距离度量较好。给定 n 维的两个样本点 p 和 q，两者的相似性为：

$$cos(\theta) = \frac{\sum_{i=1}^{n}(p_i \times q_i)}{\sqrt{\sum_{i=1}^{n}(p_i)^2} \times \sqrt{\sum_{i=1}^{n}(q_i)^2}} \qquad \text{（式3. 1）}$$

公式 3.1 表示 p，q 两点向量之间的夹角余弦值，值越大，则两点越相似。

中国知网 https://www.cnki.net

3.2 IHCE 算法

集成式增量学习在训练阶段，通常是用新获得的数据块训练一个或者多个基分类器加入到集成分类器中。如何将基分类器进行结合是集成式增量学习最为关键的一步，在以往的大多数研究中，多采用加权投票的方式进行结合，基分类器权重来源于该分类器在当时训练集上的分类能力，也就是说基分类器一旦训练完成，分类器的权重在预测不同的待测样本时是不变的。有可能基分类器当时在训练集上分类能力好，获得较高的权重，但对预测数据的分类能力差。这在数据流中尤为常见，所以针对实时的数据调整基分类器投票权重显得非常重要。

IHCE 算法主要从 3 方面入手：（1）采用异构的方式构建集成模型：对于新获得的数据，采用不同的分类算法分别训练分类器可提高基分类器之间的差异性；（2）用实时的数据调整基分类器的投票权重，以适应数据的变化；（3）在分类器的预测阶段，兼顾基分类器的历史表现和对待测样本的适应性，得到分类器对当前待测样本更合理的投票权重。算法基本框架如图 3.2 所示。

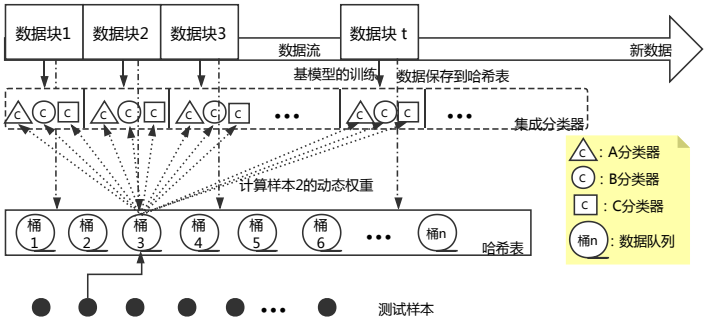

图 3.2 IHCE 算法示意图

3.2.1 LSH 保存数据分布梗概

IHCE 算法在算法训练之初建立一张空的哈希表，针对每个时间段获得的数据块，将数据分别映射到表中多个固定容量的哈希桶中，若一个桶中的数据超过其容量，则用新数据替换最旧的数据。通过对多个数据块的处理，建立一张保存了数据分布梗概的哈希表。

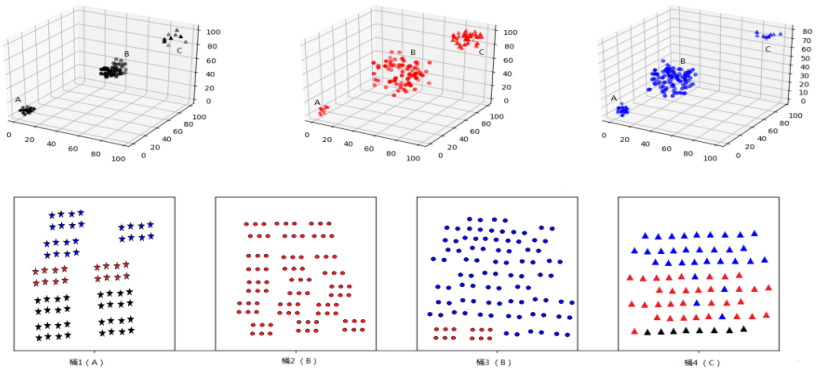

图 3.3 LSH 保存数据分布梗概

中国知网 https://www.cnki.net

如图 3.3 所示，以 3 维数据为例，用包含 4 个哈希桶的 LSH 对 3 个数据块进行处理。假设 B 区域数据经哈希映射落入桶 2、桶 3 中，因该区域数据相对于其他区域数据较多且分布较广，所以桶 2 和桶 3 中的数据更新非常快，这样可以快速适应数据动态的变化；而对于数据分布较少的 A 区域，桶 1 中完整地保存 3 个数据块中 A 区域的数据，这样可以很好保存数据分布的梗概。

3.2.2 更新投票权重和训练基分类器

IHCE 算法训练阶段，首先会用当前数据块对集成分类器中的每个基分类器进行测试，用该分类器对应的分类准确率更新其投票权重 α ，更新公式如下：

$$\alpha_k^j = \alpha_{k-1}^j + \frac{acc - \alpha_{k-1}^j}{k} \qquad (式3.2)$$

式中：acc 是第 k 个数据块上训练的第 j 个基分类器的分类准确率，α_{k-1}^j 是第 j 个基分类器在第 k–1 个数据块上的投票权重。

IHCE 算法用异构的方式组建集成模型，对于新获得的数据块，为提高基分类器之间的差异性，用多种不同的分类算法在数据块上分别训练一个基分类器，将训练完成的多个基分类器加入到集成模型中。

3.2.3 针对待测样本计算基分类器动态权重

IHCE 算法预测阶段，加入了能度量待测样本与基分类器适应性的动态权重。算法先从哈希表的桶中找出与待测样本相似的 a 个训练样本，用每个基分类器对这 a 个点进行分类，分类准确率就是该基分类器针对待测样本的动态权重，计算公式(2)如下：

$$\beta_k^j = \frac{1}{a}\sum_{t=1}^{a}(C_k^j(\mathrm{x}_t)=\mathrm{y}_t) \qquad (式3.3)$$

3.2.4 算法实现

IHCE 算法在训练阶段，获得新数据块后，算法主要有 3 步：（1）用数据对集成模型中的每个基分类器进行测试，用分类准确率更新基分类器的投票权重；（2）将数据块中的数据映射进敏感哈希表的某个桶中，如果该桶已满，则用最新数据替换最旧的数据；（3）用多种不同的分类算法在该数据块上训练多个基分类器，加入到集成模型中。预测阶段由 3 部分组成：（1）将待测样本映射进某个哈希桶中，可认为该桶中的数据与待测样本是相似的；（2）用这些相似数据去评估基分类器与待测样本的适应性，得到每个基分类器针对待测样本的动态权重 β ；（3）

中国知网 https://www.cnki.net

将基分类器的投票权重 α 与针对待测样本所获得的动态权重 β 结合得到该基分类器综合权重，用多个基分类器综合权重加权投票判定待测样本的类别。算法流程如图 3.4 所示：

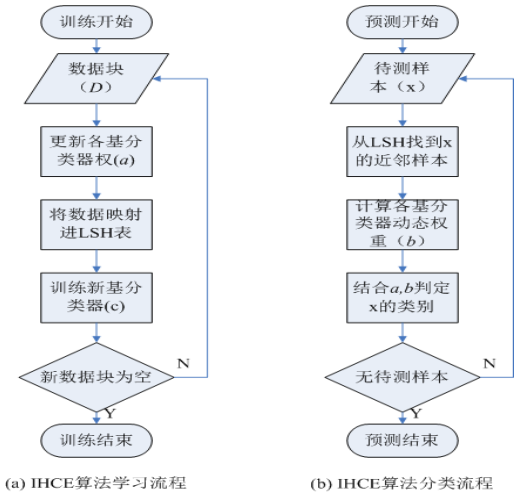

图 3.4 IHCE 算法流程图

IHCE 算法描述：

输入： 数据流 $DS=\{D_1,D_2,...D_k\cdots\}$，$m$ 种分类算法 $\{A_1,A_2...A_m\}$，测试样本 x，哈希桶数量 c 及容量 s。

输出： 带投票权重的基分类器集合 E_c，保存数据流梗概的哈希表 HT。

训练过程：

步骤 1 （1）创建一张包含了 c 个桶，每个桶容量为 s 的空哈希表 HT。（2）在数据块 D_1 上用分类算法 $\{A_1,A_2...A_m\}$ 训练得到 m 个基分类器 $\{C_1^{A_1},C_1^{A_2}...C_1^{A_m}\}$ 加入集成分类器 E_c。（3）将 D_1 数据映射到哈希表 HT 中。

步骤 2 （1）用 D_k 测试 E_c 中的基分类器，使用公式（1）更新基分类器的投票权重。（2）将 D_k 中的数据通过哈希函数映射到哈希表 HT 某个哈希桶中，如果桶容量已满，用最新数据代替最旧的。（3）用 $\{A_1,A_2...A_m\}$ 在 D_k 上学习得到 m 个基分类器 $\{C_k^{A_1},C_k^{A_2}...C_k^{A_m}\}$ 加入集成模型 E_c。

步骤 3 读入下一数据块，如果数据块为空，结束训练过程；否则回到步骤 2。经过 k 次学习，得到集成模型为：$E_c=\{C_1^{A_1},C_1^{A_2}...C_1^{A_m}...C_k^{A_1},C_k^{A_2}...C_k^{A_m}\}$。

预测样本 x：

步骤 4 将 x 通过哈希函数映射到 HT 中，找出与待测样本 x 相似的多个数据组成临时测试集 D_s。

步骤 5 对于 E_c 中 $k*m$ 个基分类器：

每个基分类器 $C_i^j, i=1,...k, j=1,...m$ 分别对 D_s 进行分类测试，用公式 3.3 计算分类器的动态权重 β_i^j。

最终 对于待测样本 x，集成分类器为 $f(x)=\sum_{i=1}^{k}\sum_{j=1}^{m}\alpha_i^j C_i^j(x)*\beta_i^j$。

中国知网 https://www.cnki.net

3.2.5 算法时间复杂度

设 k 为学习次数，n 为获得的数据块大小，有 m 种分类算法。IHCE 算法训练阶段的耗时分析：（1）用 m 种分类算法在数据块上训练分类器所需时间是 $O(mn)$；（2）将数据块中数据映射到哈希表所需时间为 $O(n)$；（3）更新 $(k-1)*m$ 个基分类器的权重所需时间为 $O(n*(k-1)*m)$。预测样本所需时间由两部分组成：（1）首先找待测样本的近邻时间为 $O(1)$，计算基分类器在 a 个近邻数据上的准确率时间为 $O(m*(k-1)*a)$，$n \gg a$，m 一般情况下较小（<10）。综上所述，当获得一个数据块，IHCE 算法处理的时间近似于 $O(n*k*m)$。

3.3 实验结果与分析

本文选择了 4 种增量学习算法作为对比算法，在 9 个数据集上做了仿真实验，以验证 IHCE 算法的有效性。所有实验均在 Inter(R) Core(TM) i5-4590S @3.00 GHz，Windows7 操作系统上采用 Python2.7 实现。

3.3.1 实验数据集

本文实验数据集来源于 UCI 数据库中 9 个真实的数据集。每个数据集中都仅包含两类数据，将数据类标签统一成{+1，-1}两类，将每个数据集等量分成 10 个数据块，基本信息见表 3.1。

表 3.1 实验数据集信息

数据集	样本数	特征数	数据块大小
banknote_aut	1370	4	137
biodeg	1050	41	105
sonar	210	60	21
Diabetic	1160	19	116
Liver-disorder	380	6	38
ionoshphere	360	34	36
waveform	3360	40	336
Crowdsourced	10560	29	1056
svmguide	12500	23	1250

3.3.2 实验设置

本文选择了 4 个常见的增量学习算法作为对比算法：增量 Passive-Aggressive 算法[62]（IPA）、Learn++算法[8]、增量 SGD 算法[75]（ISGD）和 Adaptive Budget Perceptron 算法[76]（ABP）。集成模型中的基分类算法统一选用决策树，由于 IHCE 算法是异构的，因此还加入支持向量机和 AdaBoost 两种算法。对比算法的参数来

中国知网 https://www.cnki.net

源于原文献的实验参数。IHCE 算法中的另外两个主要参数分别是：哈希桶的个数和桶容量，增加桶的数量和容量可以提升算法的性能，但会增加存储空间。为了兼顾算法的分类精度和空间开销，经多次实验后，设置哈希桶个数 c=10，桶容量设置为：数据块中样本数/100 。

每个数据集分成等量的 10 块，每种算法依次在前 9 个数据块上进行增量学习，最后 1 块仅用作分类器每次学习后的测试集。为了使得实验数据更加可靠，重复进行实验 5 次，并计算分类准确率的平均值。

3.3.3 实验结果与分析

图 3.5 展示了 5 种算法训练的分类器随着训练样本的增多在测试集上分类准确率的变化趋势，用折线表示每个分类器对新增数据学习后在测试集上的分类准确率的变化情况。子图中横坐标代表参加训练的数据占整个实验数据集的百分比，纵坐标则是各分类器在测试集上的分类准确率。表 2 给出了每个实验数据集上，5 种分类算法 8 次增量学习完成后，在测试数据集上的分类准确率（平均值±标准差）。

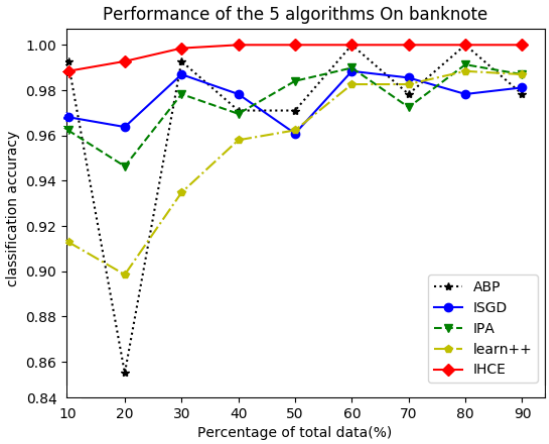

(a) banknote

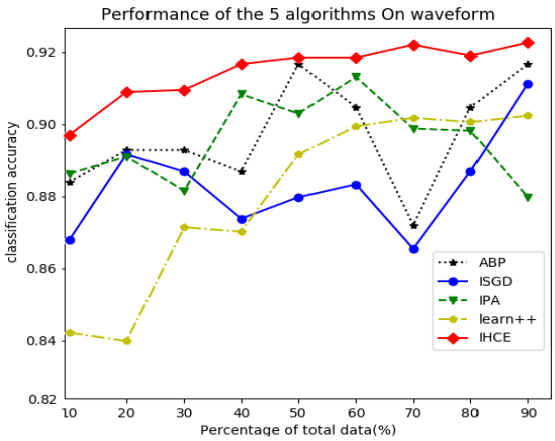

(b) waveform

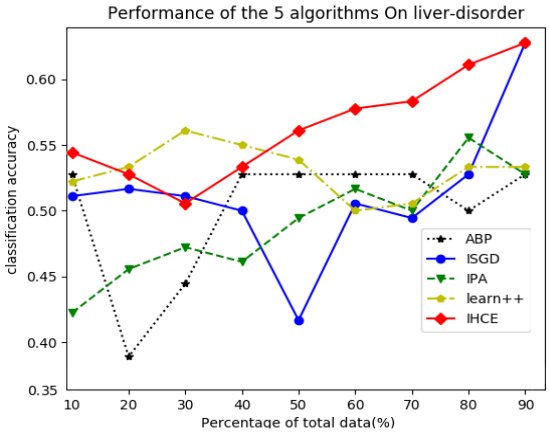

(c) liver-disorder

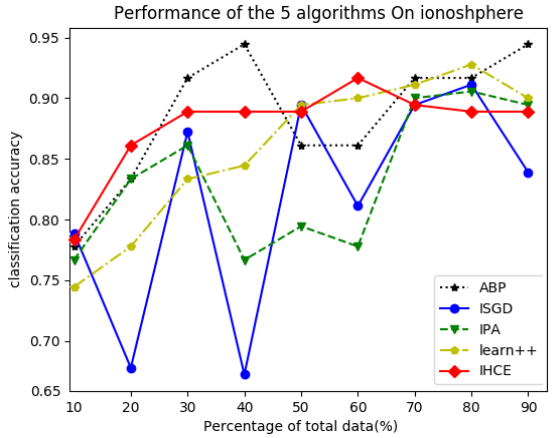

(d) ionoshphere

中国知网 https://www.cnki.net

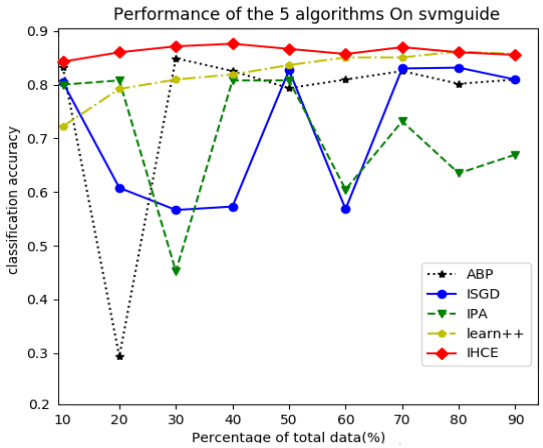

(e) svmguide

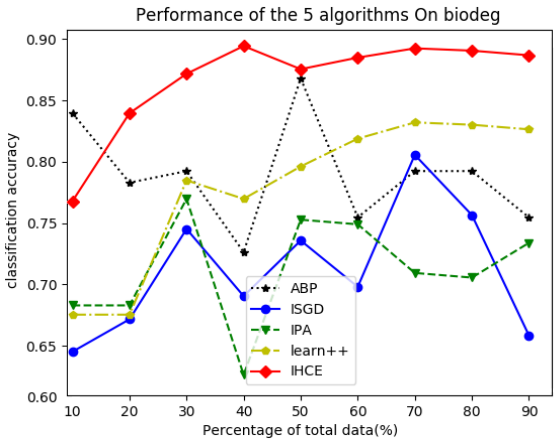

(f) biodeg

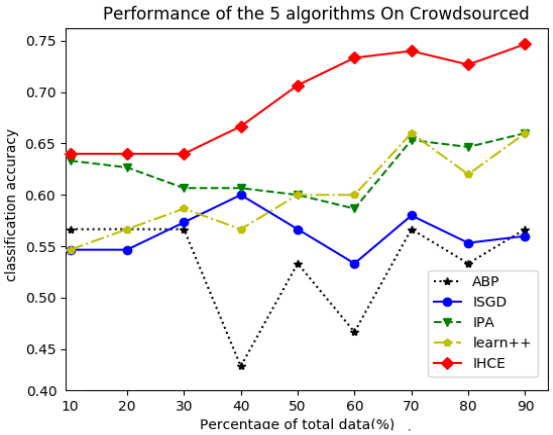

(g) Crowdsourced

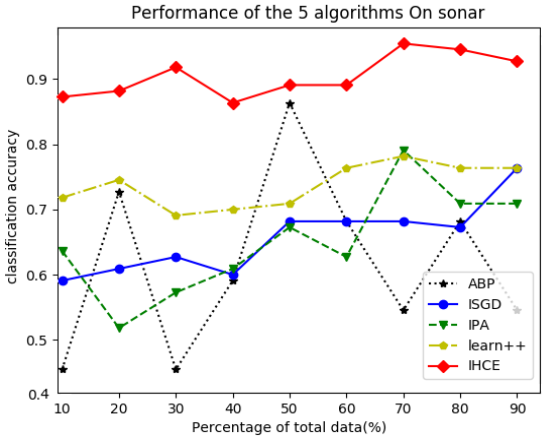

(h) sonar

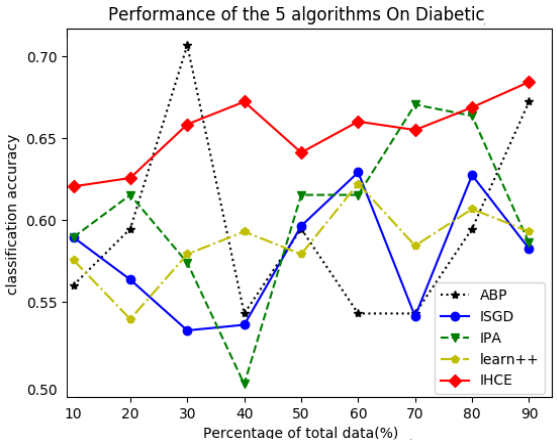

(i) Diabetic

图 3.5　5 种算法在 9 个数据集上增量学习表现

从图 3.5 可以看到，在数据集 banknote、svmguide 和 Diabetic 上，5 种分类算法训练的分类器随着训练集增加，分类准确率都没有太大的提升，主要是因为增加的训练数据和建立初始模型的数据相似。其余数据集上，IPA 和 ISGD 算法分类准确率有一定的波动，这是因为前后加入训练的数据隐含的类边界发生了较大的

中国知网 https://www.cnki.net

改变，这两种算法可塑性高，对数据的变化非常灵敏。而相比之下 IHCE 分类器和 Learn++分类器由于保留了大量先前学到的知识，用新增训练数据对模型进行微调，从而分类准确率稳步上升。

从总体上看，IHCE 算法从最初分类器的建立一直到整个学习过程完成，其分类准确率均比对比算法要高，这是因为该算法在学习过程中不仅保留了所学到的知识，而且根据新增数据实时调整基分类器的投票权重，使得集成分类器能适应数据的变化。用哈希表来保存数据流的梗概，在算法预测阶段，能通过哈希表非常迅速的找到与待测样本相似的数据，针对待测样本加入动态权重，动态地调整每个基分类器的综合权重，使集成模型能很好的应对数据分布发生突变等情况。对于数据块之间没有发生明显分布变化的数据集 banknote、svmguide、Diabetic，IHCE 算法和对比算法相比分类准确率稍高；对于前后发生明显变化的另 6 个数据集，IHCE 算法比对比算法有更加显著的分类效果。

表 3.2 5 种算法在 9 个数据集上学习表现对比

数据集	分类准确率(%)				
	ABP	IPA	ISGD	Learn++	IHCE
banknote	97.80 ± 0.00	98.66 ± 1.83	98.11 ± 1.65	98.75 ± 2.77	**99.09 ± 0.09**
liver-disorder	52.77 ± 0.00	52.70 ± 3.73	62.72 ± 9.13	53.34 ± 1.77	**62.77 ± 1.50**
Diabetic	67.26 ± 0.03	58.57 ± 0.76	58.29 ± 0.89	59.71 ± 0.74	**68.60 ± 3.08**
biodeg	75.47 ± 0.08	73.39 ± 0.87	65.87 ± 2.03	82.57 ± 2.33	**88.46 ± 0.92**
ionoshphere	**94.41 ± 0.01**	89.53 ± 2.32	83.88 ± 1.65	90.00 ± 5.14	89.88 ± 0.24
waveform	91.66 ± 0.00	87.99 ± 4.83	91.15 ± 0.98	90.29 ± 2.85	**92.24 ± 0.67**
Crowdsourced	56.67 ± 0.01	66.02 ± 0.86	50.07 ± 0.59	66.52 ± 0.21	**74.62 ± 2.94**
svmguide	81.95 ± 0.42	69.76 ± 9.34	71.82 ± 6.06	79.53 ± 2.94	**85.47 ± 1.09**
sonar	54.55 ± 0.01	70.95 ± 7.25	76.36 ± 9.55	76.80 ± 7.71	**92.74 ± 5.18**

综合图 3.5 和表 3.2 的结果可知：当完成 9 个数据块的增量学习后，本文提出的 IHEC 算法在 8 个数据集上的分类准确性都比对比算法要高，其中在 biodeg、Crowdsourced 和 sonar 数据集上表现的非常明显，本算法能较好地兼顾增量学习中的稳定与可塑性，有一定的通用性。IHCE 算法由于在训练阶段会对基分类器权重做实时更新，理论上要比 4 种对比算法耗时更多，实验过程中发现：ABP、IPA 和 ISGD 算法用时明显少于 IHCE 和 Learn++算法，但 IHCE 算法在有些数据集上运行所花费的时间甚至比 Learn++算法要短。这是因为 Learn++算法在训练分类器的过程中，对带权重的样本随机采样用于基分类器的训练，如果训练的基分类器误分类样本权重之和大于 0.5，则舍去该基分类器。这就导致 Learn++算法需要反复取样来训练基分类器，以达到用户设定的基分类器数量。

中国知网 https://www.cnki.net

综上所述，本文提出的 IHCE 算法在保留了以前学到的知识的情况下，还能很好地应对数据发生变化等情况。在 9 个实验数据集上显示：IHCE 算法分类准确率通常高于常用的 4 种增量学习算法，而且学习过程更加稳定，说明了本文提出的 IHCE 算法是有效的。

3.4 结论

增量学习模型应尽量多保存已经学到的知识，还能很好地应对数据的变化。针对以往集成式增量学习算法的不足，提出了基于多分类器异构的集成式增量学习算法（IHCE），通过多分类器异构的方式增加了基分类器之间的差异性，用 LSH 表和多个分类器保留了所学到的知识，实时更新基分类投票权重，并在预测阶段加入针对待测样本的动态权重，以调整基分类器的综合权重，使得模型适应数据动态的变化，在多个数据集上的仿真实验证明了该算法能较好地应对增量学习中稳定-可塑性难题，是有效的。但 IHCE 算法和大多数集成式增量学习算法一样，随着学习的进行，模型规模会变得比较庞大。今后，在提高分类准确率的同时提高算法运行速率还需要进一步研究。

中国知网 https://www.cnki.net

4 基于选择性学习的增量学习算法

将集成学习用于增量学习之中可以提高模型的稳定性和泛化能力，常见的集成式增量学习算法有 Learn++算法[8]和 NCL 算法[77]。集成式增量模型不但可以完整的保留已经学到的知识，对于基分类器的要求与操作也相对于单分类模型更简单，因为在增量学习过程中，可以对每个数据块的学习看成是批量学习任务，对新获得的数据训练一个基分类器加入到集成模型之中。但大多数集成式的增量学习方法主要有如下 2 个缺点：（1）随着学习次数的增加，集成模型的规模会逐渐变大，多余的分类器会耗费大量的存储空间，同时拖慢集成模型的预测速度。（2）数据流中的数据一旦发生数据分布或隐含知识的变化，在产生变化之前所训练的分类器可能对当前预测数据变得无关紧要，很有可能这些分类器对先前的数据分类能力比较好，获得了非常重的“话语权”，而这会极大的影响到发生变化后待测数据的类别判定。

为应对集成式增量学习中集成模型的规模会随着学习次数的增加而变得庞大等问题，固定规模的集成式增量模型[78][79]被提出，主要是通过人为地设置一个集成模型容量，当集成模型中基分类器的数量达到设定的阈值时，将某个评估指标下性能不好的分类器丢弃，这种方法可以控制集成模型的无限增加，但是会造成“知识遗忘”。整体上看，大多数的算法均采用“over produce and choose”策略[80]，先训练许多分类器然后进行选择集成，这种方法在批量学习中有大量的应用。在增量学习中，因为学习次数是无限的，数据的变化相对于基于静态的数据集更大且重复数据更多，用每个新获得的数据块都重新训练模型，将会训练许多相识度很高的基分类器。

本论文第三章中提出的 IHCE 算法虽然能够提升模型的分类准确率，但是其模型的规模会随着学习次数的增多变大，如何用规模较小的模型保存尽量多的知识，且使得模型之间的差异性尽可能大。针对此问题，本文从减小集成模型的规模和增大基分类器的差异性出发，结合 Stacking 方法提出了一种轮转式的集成增量学习算法(Incremental Learning Algorithm based on Rotary-Table Classifier Ensemble，IRTCE）。这和 IHCE 算法不同，该算法要求基分类模型具有增量学习能力，其过程分为 2 部分：在训练阶段不再是一味的训练基分类器加入集成模型中，而是从集成模型中选择一个合适的基分类器对新获得的数据进行增量学习，当集成模型中找不到合适的基分类器对数据进行增量学习时，才用新数据训练一个基分类器加入集成模型，从而控制了集成模型的规模，同时得到多个具有较大差异性的分类器；当需对待测样本进行预测时，采用 Stacking 方法对基分类器进行组合。

中国知网 https://www.cnki.net

4.1 基分类器的组合

4.1.1 选择性集成

对于海量高维的数据流，传统的集成式增量学习集成模型的规模在增量学习过程中会随着学习次数无限制的变大，如果不对集成模型的规模加以限制，经过多次增量学习后集成模型会过于庞大，其中包含了许多冗余、性能不好的基分类器，可能对集成模型造成负面影响。研究人员发现在批处理算法中剔除集成模型中冗余和分类效果差的分类器可以提升集成模型的性能[50]，这相当于在基分类器训练和组合中间加入了选择分类器的过程。

根据集成学习的定义可知，要获得更好的集成效果，则需要基分类器本身具备较好的预测能力，并且基分类器之间的差异性要比较大。常用的多样性度量的方式有非成对差异性度量和成对差异性度量，成对差异性度量是计算分类器两两之间的差异性，比较的时间复杂度为$O(mn)$；非成对差异性是直接计算全部分类器之间的差异，如分簇法与迭代优化算法，增量学习产生的基分类器可能会较多，采用成对差异性度量的复杂度较高，模型需要快速处理数据流，所以直接用排序选择的方法。IRTCE 算法训练阶段完成，要比传统的集成式增量模型规模更小，基分类器之间的差异性也比较大。但增量学习中学习的次数是无限的，若数据产生环境频繁变化，仍有可能基分类器数目变得非常庞大，若达到预定阈值，IRTCE 算法只需将队列头部的基分类器（很久没用到的知识）舍去。

在增量学习中，由于数据中隐含的知识变化较大，用动态选择方法可以快速适应数据流的变化，针对每个待测样本选出一组基分类器，可以获得较好的学习效果，但这样的方式会花费非常多的时间[81]。

4.1.2 Stacking 方法

在静态数据集上训练的集成学习模型，因数据集较少，通常采用直接加权投票的方式进行结合。在增量学习中，有充足的数据用来训练基分类模型和元模型，通过学习的方式来得到更加合理的基分类器组合方式。对于静态数据集上学习得到的集成模型，分类器之间差异性不是非常大，传统的组合策略不但简单而且可以得到很好的效果。但在数据流的处理过程中，分类器的差异性可能非常大，而且分类器设置的投票权重对当前待测数据不合理。分析以往的研究发现，当数据比较充裕时，用 Stacking 方法[82]组合基分类器能达到更好的学习效果[83]。

随机森林是当前运用最广泛的算法之一[84]，它具有速度快、稳定性高、泛化能力强等优点，而且能直观的给出特征的重要性。因而被大量地用于分类和回归问题。在训练元模型时，将每个基分类器输出作为元模型的输入，在 Stacking 的元模型中，通常采用随机森林来评估基分类器的投票权重是很好的选择。

中国知网 https://www.cnki.net

4.2 IRTCE 算法

集成分类器中基分类器需相互独立，否则有一定的几率退化为单分类器模型。由于数据流中的数据大多是同源分布，数据相似性比较高，若采用传统集成式增量学习的方式会训练许多冗余的分类器。从基分类器的分类器准确性和分类器之间差异性出发，本文针对此设计了一种轮转式学习模型，本算法框架如图 4.1 所示：

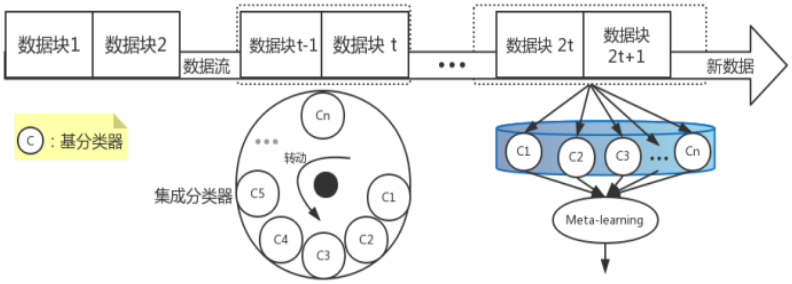

图 4.1 IRTCE 算法示意图

算法主要有 3 部分：（1）每当一个新数据块到来，旋轮转盘，任一个基分类器学习后获得更好的分类效果，即用该基分类器增量学习后的模型替换旧模型，完成对该数据块的学习。如果所有的基分类器学习后分类效果都退化，则训练一个新分类器加入集成模型中。（2）由于学习次数是潜在无限的，有可能集成模型会达到预定的阈值，删除队列头上的基分类器。（3）预测阶段则直接用最近的数据使用 Stacking 方式将基分类器的输出结合起来，以应对数据流的变化。

4.2.1 基分类器的训练

数据块 $D^t = x^t(i) \in X, y^t(i) = Y, i = 1, \ldots, n$，其中 t 是时间，类标签设置为 y^t，$x^t(i)$ 是 t 时刻的数据块中第 i 个样本。$P^t(x, y)$ 是 t 时刻的数据分布，$t+1$ 时刻的数据分布为 $P^{t+1}(x, y)$。IRTCE 算法为了控制集成模型的规模，若新数据块的数据分布以前出现过，即 $P_t(x, y) = P_k(x, y), k = 1, 2 \ldots t-1$，用第 k 个基分类器进行增量学习。具体操作如下：用活动分类器窗口中的基分类器对当前数据块分类，若分类准确率大于 0.5，用该分类器对数据块进行增量学习，若增量学习前后的准确率更高，结束对该数据块的学习，若活动分类器窗口中的基分类器分类准确率小于 0.5 或者增量学习后的分类准确率更低。转动轮转，用前一个基分类器进行相同操作，若所有基分类器都不满足这两个条件，表明这样的数据分布未见过，则训练一个新模型加入集成分类器中。

这种方式的优势是，对于那些分布变化不大的数据，只需用一个基分类器进行增量学习，从而大大降低集成模型的规模。

中国知网 https://www.cnki.net

4.2.2 基分类器组合

传统的集成算法通常采用加权投票的方式将基分类器进行组合，基分类器的权重来源于训练时该基分类器对训练集的分类准确率。由于数据流中的数据在快速的变化，所以传统的结合方法不适应于增量学习。在 IRTCE 算法中，因为基分类器在训练集上的分类能力不能用来衡量在新数据集上的分类能力，而且基分类器增量学习了不同时间段的数据，对基分类器如何结合将极大的影响集成模型的分类准确率。根据数据流的动态变化性可知，用静态权重显然不合适，而采用动态权重的方式会花费较多的时间[85]。IRTCE 算法训练阶段训练得到若干个差异性大的基分类器。由于数据流中的数据充足，选出部分未使用的数据用于元模型的训练，通过 Stacking 方法将基分类器输出的结果输入随机森林算法，训练得到随机森林分类器模型，该模型可以评估每个基分类器对最终结果影响的大小。

4.2.3 算法实现

IRTCE 算法描述：

输入：数据流 $DS=\{D_1,D_2,...D_k\cdots\}$；基分类算法 A；元学习算法，随机森林；集成模型规模 S。

输出：t 时刻下的基分类器集合 E_t。

步骤 1 （1）在数据块 D_1 上用分类算法 A 训练得到基分类器 C_1 加入队列 E_1 中。（2）将 D_1 数据加入缓冲区 cache 中。

步骤 2 （1）用 D_t 和 cache 测试 E_t 中队尾的基分类器 C_n，分别记录分类准确率 A_{hk},A_{hc}。用 C_n 对 D_k 进行增量学习得到 $C_n i$，用 D_k 和 cache 中的数据测试 $C_n i$ 得到分类准确率 A_{ak},A_{ac}，若 $A_{ak}>A_{hk}$，且 $A_{ac}>A_{hc}$ 用增量模型代替原模型，转到步骤 3，若不满足上述条件，用前一个基分类进行相同操作。（2）若集成模型中所有基分类增量学习后都不满足 $A_{ak}>A_{hk}$，且 $A_{ac}>A_{hc}$，则用 D_k 重新训练一个基分类器加入集成模型 E_t。若容量已满，则删掉队列头基分类器。（3）集成分类器达到预定阈值，删除队列头的基分类器。

步骤 3 读入下一数据块，如果数据块为空，结束训练过程；否则回到步骤 2。

经 t 次学习，得到集成模型为：$E_t=\{C_1...C_n\}$。

步骤 4 用最近获得的数据块组成临时测试集 D_s，随机森林对基分类器的权重进行评估，得到基分类器的投票权重 β_i，舍去权重极小的分类器。

步骤 5 对于 E_c 中 n 个基分类器：每个基分类器 $C_i, i=1,...n$ 分别对待测样本进行预测，通过加权方式得到最终预测类别，集成分类器为

$$f(x)=\sum_{i=1}^{k}C_i(x)*\beta_i \quad (式4.1)$$

中国知网 https://www.cnki.net

4.3 实验结果与分析

本文选择了 4 种增量学习算法作为对比算法，在 9 个数据集上做了仿真实验，以验证 IRTCE 算法的有效性。所有实验均在 Inter(R) Core(TM) i5-4590S @3.00 GHz，Windows7 操作系统上采用 Python2.7 实现。

4.3.1 实验数据集

本文实验数据集来源于 MOA（Massive Online Analysis）生成的 3 个数据集，UCI 数据库中选取 6 个真实的数据集。每个数据集中都仅包含两类数据，将数据类标签统一成两类，将每个数据集等量分成 20 个数据块，基本信息描述见表 4.1。

表 4.1 实验数据集信息

数据集	样本数	特征数	数据块大小
banknote	1380	4	69
biodeg	1060	41	53
Diabetic	1160	19	58
waveform	3360	40	168
Crowdsourced	10560	29	528
svmguide	1260	23	63
hyperplan	100280	10	5014
GradualDrift	200000	21	10000
SEA	1000000	3	50000

4.3.2 实验设置

本文选择了 4 个常见的增量学习算法作为对比算法：增量 Passive-Aggressive 算法（IPassiveAggressive）[62]、Learn++算法[8]、增量 SGD 算法（ISGD）[75]和增量 BernoulliNB 算法（IBernoulliNB）[76]。Learn++采用决策树作为基分类算法，每次迭代训练产生 1 个基分类器。对比算法的参数来源于原文献的实验参数。本章提出的 IRTCE 算法基分类采用增量 SGD 算法（ISGD）。

每个数据集分成等量的 20 块，每种算法依次在前 19 个数据块上进行增量学习，最后 1 块仅用作分类器每次学习后的测试集。为了使得实验数据更加可靠，重复进行实验 10 次，并计算分类准确率的平均值。

4.3.3 实验结果与分析

图 4.2 展示了 5 种算法训练的分类器在测试数据上分类准确率的变化趋势，用折线表示集成模型对增量学习后分类准确率的变化情况。子图中横坐标代表参加训练的数据占整个实验数据集的百分比，纵坐标则是各分类器在测试集上的分类准确率。表 4.2 给出了在 9 个实验数据集上，5 种分类算法经 19 次增量学习完成

中国知网 https://www.cnki.net

后，在测试数据集上的分类准确率（平均值±标准差）。

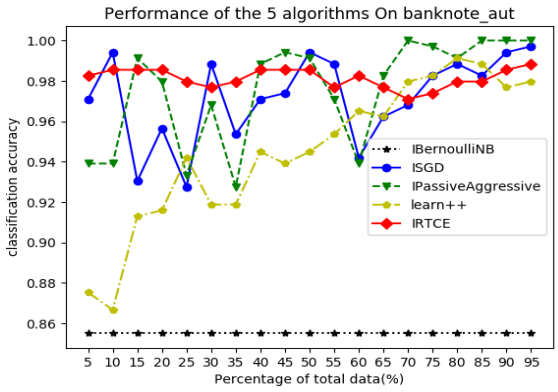

(a) banknote

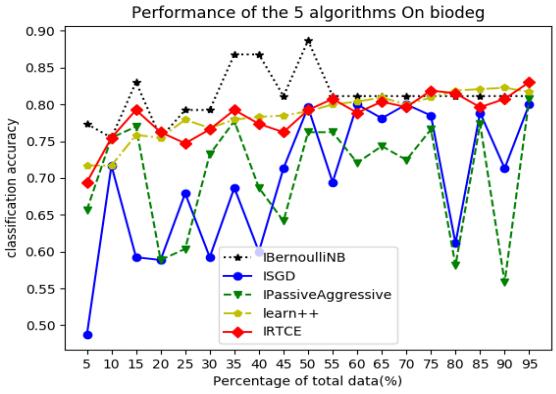

(b) biodeg

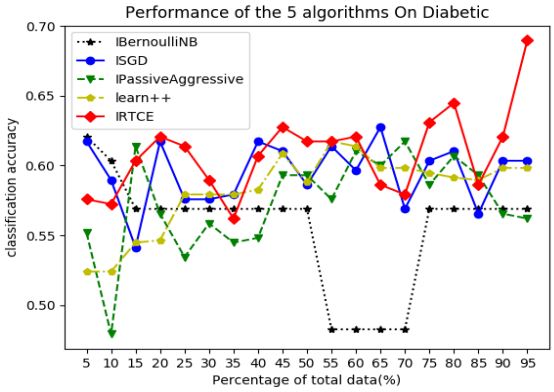

(c) Diabetic

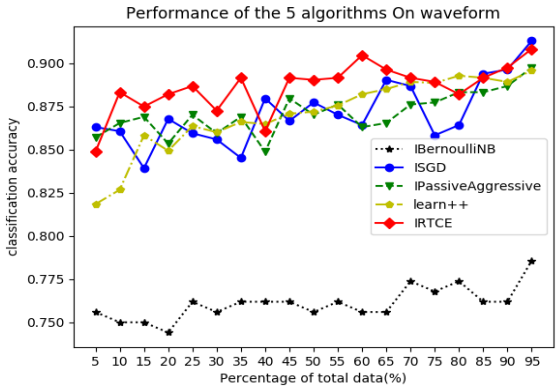

(d) waveform

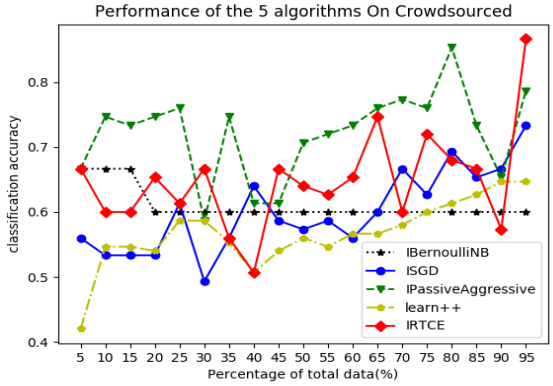

(e) Crowdsourced

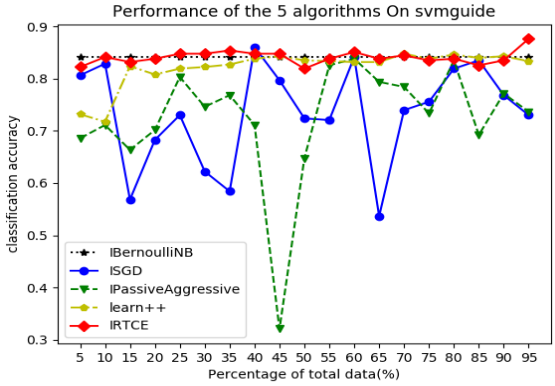

(f) svmguide

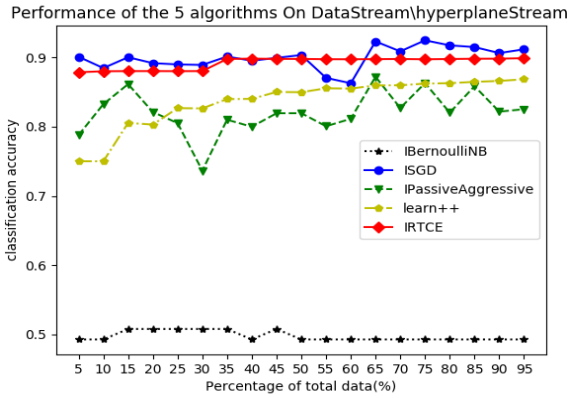

(g) hyperplan

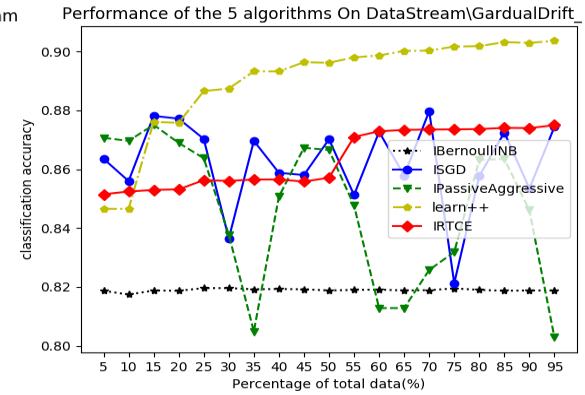

(h) GardualDrift

中国知网 https://www.cnki.net

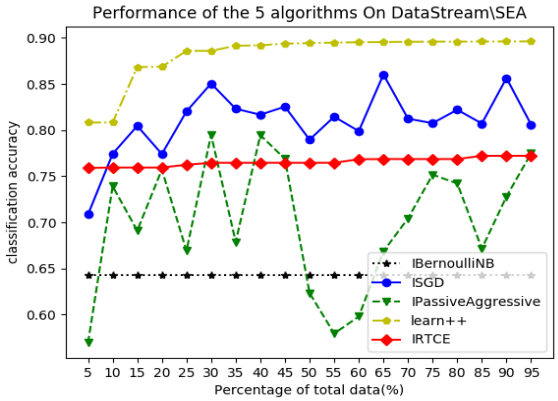

(i) SEA

图 4.2 5 种算法在 9 个数据集上增量学习表现

由图 4.2 可以看出，5 种增量学习算法在 9 个数据集上随着学习样本的增多，从整体上看分类准确率有所提高，但 Learn++和 IRTCE 算法表现的更加稳定，其分类精度随着学习次数的增加稳步提升，这是因为有可能某个数据块中的数据因为环境的变化，产生了一些噪声，而多个分类器的加入可以使得集成模型更加稳定；而另外三种算法在学习过程中有较大的波动，这是因为单分类器增量学习算法对数据的变化非常敏感，如果新数据隐含的知识与已学到的知识有较大变化，则算法需要调整其结构或者参数以适应数据的变化，而有可能是这个数据块包含了较多的噪声。

对于有些数据集，例如 svmguide 和 hyperplan 数据集，各分类算法精确率提升比较缓慢，这是因为新获得的数据集与集成模型先前学到的知识相似度比较高，对新数据的增量学习并没有多大程度上提升模型的分类准确性。

表 4.2 5 种算法在 9 个数据集上学习表现对比

数据集	分类准确率(%)				
	INB	IPA	ISGD	Learn++	IRTCE
banknote	85.50 ± 0.00	97.40 ± 2.29	97.28 ± 2.24	95.62 ± 3.37	**98.19 ± 0.67**
Diabetic	55.86 ± 3.83	60.57 ± 2.26	58.89 ± 3.17	63.71 ± 2.74	**66.60 ± 3.08**
biodeg	81.13 ± 0.00	80.75 ± 2.47	80.07 ± 2.56	81.67 ± 0.43	**83.06 ± 0.62**
waveform	78.57 ± 0.01	89.76 ± 3.83	**91.30 ± 1.78**	89.59 ± 1.45	90.84 ± 1.45
Crowdsourced	60.01 ± 0.00	78.66 ± 1.83	73.33 ± 8.16	64.66 ± 5.51	**86.22 ± 1.24**
svmguide	84.12 ± 0.02	73.66 ± 2.34	73.02 ± 2.76	83.33 ± 0.94	**87.47 ± 2.69**
Hyperplan	49.24 ± 0.00	82.53 ± 5.69	**91.20 ± 2.28**	86.86 ± 0.33	89.91 ± 4.02
GardualDift	81.88 ± 0.00	81.28 ± 5.70	87.43 ± 1.35	**90.35 ± 1.50**	88.49 ± 1.84
SEA	64.28 ± 0.00	77.47 ± 5.79	80.59 ± 3.83	**88.60 ± 0.00**	77.57 ± 9.83

从表 4.2 和图 4.2 中可以看出，本文所提出的 IRTCE 算法的分类准确率与 Learn++算法非常的近，只是在 SEA 公共数据集上分类准确率明显低于 Learn++算

中国知网 https://www.cnki.net

法，这可能是因为基分类的数目过少，在用 Stacking 进行学习时，每个基分类学习到的权重不太适应于当前的预测数据。在多数实验数据集上的分类准确率好于另外 3 种增量学习算法。

表 4.3 各数据集上 5 种算法的运行时间(s)和 IRTCE 规模

数据集	INB	IPA	ISGD	Learn++	IRTCE
banknote	0.0125	0.0078	0.0079	0.1953	0.427 (4.4)
biodeg	0.0705	0.0477	0.0483	1.0609	1.889 (5.6)
Diabetic	0.0690	0.0485	0.0500	1.1128	2.146 (7.2)
waveform	0.0773	0.0429	0.0436	2.1487	1.910 (3.4)
Crowdsourced	0.0518	0.0336	0.0348	0.4074	1.939 (7.2)
svmguide	0.0551	0.0379	0.0346	0.5440	1.386 (5.8)
Hyperplan	0.2106	0.1575	0.1530	228.3	2.253 (3.2)
SEA	0.4111	0.4814	0.4689	3047	3.063 (3.0)
GardualDift	0.3006	0.1404	0.1335	377.7	1.110 (3.2)

从表 4.3 中可以看出，IRTCE 算法和 Learn++算法所用的时间相差不是很大，但是它们比另外 3 种算法要多，这是因为在学习过程中，单分类器模型只需要调整其内部参数，模型的规模没有增大，而 Learn++是因为基分类器增多，在对新样本进行预测时，所用的时间会直线上升；而 IRTCE 算法基分类器数量不会直线增加，但是在训练过程中增加了选择基分类器进行学习的过程。在一些数据量较少的实验数据集上，IRTCE 算法所用的时间要多于 Learn++算法，但是对于数据量较大地超平面数据集、SEA 公共数据集和 GardualDrift 数据集，其所用的时间明显要比 Learn++更少。经过 20 次学习过后，Learn++算法学习完成后基分类器的个数为 20 个，而 IRTCE 很多时候只需要 5 个上下的基分类器，规模远小于传统的集成式增量学习算法 Learn++，这说明了该算法能在保证其分类准确率的情况下，大幅度降低集成模型的规模，证明了该方法的有效性。

4.4 本章小结

为了克服集成式增量模型规模变得庞大等问题，之前的研究多是将某些性能不好的基分类器直接舍去，这种做法可能造成“知识的遗忘”。本章内容将选择性集成与 Stacking 用于集成式增量式学习，在基分类器的训练阶段，为了使得训练的基分类器少且能完整的保存所学到的知识，同时为了增大基分类器之间的差异性，当训练样本到来，首先从集成模型中选择一个对当前数据适宜的分类器进行增量学习，一旦分类性能有所提高，则不需要再添加新的基分类器，除非在集成模型中没有找到适合用于对该数据块进行增量学习的基分类器，才会训练一个新

中国知网 https://www.cnki.net

的基分类器加入集成模型。而在分类器的预测阶段，通过选择较好的基分类器通过 Stacking 的方式重新学习分类器的权重，以对新的样本做出预测。实验发现，提出的 IRTCE 在保证了其分类准确率的情况下，较大程度的降低了集成模型的规模。具有很好的泛发性能，同时说明了 IRTCE 算法的有效性。

中国知网 https://www.cnki.net

5 研究结论与展望

5.1 研究结论

集成式增量学习结合了集成学习的优点，对于数据流中的数据不断变化的特点，集成式增量学习用多个基分类器保存学到的知识，使得模型能够较为完整的保留已经学到的知识，还可以提升模型的稳定性。为了提升模型的精度，本文将集成学习的诸多技术引入了增量学习之中。为了解决集成式增量学习集成模型的规模庞大等不足之处，引入了选择性学习方法对集成模型进行了精简。本文主要研究内容包括了以下三个方面：

① 集成学习与增量学习相关技术

本文对所涉及的集成学习和增量学习技术做了简短的介绍，主要集中在集成学习中的 Bagging，Boosting，Stacking 和选择性集成技术；对增量学习中的集成式增量学习做了较为详细的阐述。

② 基于异构分类器集成的增量学习算法

采用增量学习的方式对数据流中的数据进行学习，考虑到集成学习中需要尽可能增大基分类器之间的差异性，本文用异构的方式组建集成模型，在学习过程中不断调整分类器的权重以适应数据流的变化，为使基分类器的投票权重对待测样本更加合理，用与待测样本相似的训练样本作为桥梁，为每个基分类器设置一个动态权重，在预测阶段，通过基分类器的双权重以得到待测样本的预测结果。在实验数据集上验证了该方法的有效性。

③ 基于选择性学习的增量学习算法

针对集成式增量学习中模型的规模会随着学习次数的增加逐渐增大的问题，本文采用在集成模型中选择一个合适的分类器对新获得的数据进行增量学习，这样不但能够减少基分类器数量、增大基分类器的差异性，还能较为完整的保留已经学到的知识。实验表明，该方法能够在保证分类准确率的前提下，大幅度的降低集成模型的规模。

5.2 未来展望

本文将集成学习的思想引入到增量学习之中，采用异构的方式组建集成式增量学习模型，使得集成模型对数据的分类准确性有一定的提升。为了降低集成模型的规模，采用了轮转式的集成模型进行数据的增量学习，同时用选择性集成的方法对基分类器进行选取，在多个实验数据集上获得了较好的效果，证明了其有效性。但是仍然存在以下几点不足，需要进一步研究：

中国知网 https://www.cnki.net

① 为基分类器设置更为合理的权重

IRTCE 算法虽然在训练阶段将相近的知识保存在一个基分类器之中，也增大了基分类器之间的差异性，通过 Stacking 方法对基分类器进行结合能够达到不错的分类效果，集成模型的规模要远小于 Learn++这样的集成式增量学习算法，但分类准确率没有太大的提高，这可能是因为在 Stacking 学习过程中会损失一部分信息，在今后的研究中，尝试采用置信度投票等方式，尽可能精确地学习基模型的组合方式。

② 不平衡数据集上的处理

本文提出的两种算法都假定某一个时段数据非同类，而在实际应用中，可能会出现某个时间段内只出现某一类数据，提出的两种算法不能较好的应对这方面的情况。故今后的研究中可以尝试对样本的类别分配一定的权值，以使得少数类有足够的“话语权”，以进行有效的处理。

中国知网 https://www.cnki.net

参考文献

[1] N Littlestone. From on-line to batch learning[C]// The Workshop on Computational Learning Theory, COLT 1989, Santa Cruz, Ca, Usa, July 31 - August. DBLP, 1989:269-284.

[2] H W Coppock, J E Freund. All-or-none versus incremental learning of errorless shock escapes by the rat. Science[J]. 1962, 135(3500):318-319.

[3] R Polikar, J Byorick, S Krause. Learn++: A classifier independent incremental learning algorithm for supervised neural networks[J]. Proc. of Int. Joint Conference on Neural Networks, 2002(2):1742–1747.

[4] J Gama, I Zliobaite, A Bifet, et al. A survey on concept drift adaptation[J]. ACM Computing Surveys. 2014, 46(4):44:1-44:37.

[5] I Zliobaite, M Pechenizkiy, J Gama. An Overview of Concept Drift Applications[M]. [S.1.]: Springer International Publishing, 2016: 91-114.

[6] J Sun, H Li, H Adeli. Concept drift-oriented adaptive and dynamic support vector machine ensemble with time window in corporate tinancial risk prediction[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems. 2013, 43(4):801-813.

[7] 陈兆乾,周志华,李红兵,谢俊元.混合型学习模型 HLM 中的增量学习算法[J].软件学报,1997(11):875-880.

[8] W N Street, Y S Kim. A streaming ensemble algorithm (SEA) for large-scale classification[C]// ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2001:377-382.

[9] R Polikar, L Upda, S S Upda, et al. Learn++: an incremental learning algorithm for supervised neural networks[J]. IEEE Transactions on Systems, 2001, 31(4):497-508.

[10] M D Muhlbaier, A Topalis, Polikar R. Learn++.MT: A New Approach to Incremental Learning[C]// International Workshop on Multiple Classifier Systems. Springer, Berlin, Heidelberg, 2004:52-61.

[11] M D Muhlbaier, A Topalis, R Polikar. Learn++.NC: combining ensemble of classifiers with dynamically weighted consult-and-vote for efficient incremental learning of new classes[J]. IEEE Transactions on Neural Networks, 2009, 20(1):152.

[12] G Ditzler, M Muhlbaier, R Polikar. Incremental Learning of New Classes in Unbalanced Datasets:Learn++. UDNC[J]. Multiple Classifier Systems, 2010(4):33-42.

[13] G. Ditzler, R Polikar,N. Chawla. An Incremental Learning Algorithm for Non-Stationary Environments and Class Imbalance[C]. International Conference on Pattern Recognition,2010:2997-3000.

中国知网 https://www.cnki.net

[14] M Muhlbaier, R Polikar. An ensemble approach for incremental learning in nonstationary environments[J]. Workshop on Multiple Classifier Systems ,2007(5):490-500.

[15] G Ditzler, R Polikar. Semi-supervised Learning in Nonstationary Environments[C]. JointConf. on Neural Networks,2011:2741-2748.

[16] G Ditzler, R Polikar. Incremental Learning of Concept Drift fromStreaming Imbalanced Data[J]. IEEE Transactions on Knowledge And Data Engineering,2013,25(10):2283-2231.

[17] R Ramachandran, K D Dahm, R Nickel. Vertical integration of biometrics across the curriculum: case study of speaker, face and iris recognition[J]. IEEE Circuits and Systems Magazine, 2014 (14): 55-69.

[18] K Dyer, R Capo, R Polikar. COMPOSE: A Semi-Supervised Learning Framework for Initially Labeled Non-Stationary Streaming Data[J]. IEEE Transactions on Neural Networks and Learning Systems, 2014 (25): 12-26.

[19] G Ditzler, R. Polikar. Bootstrap based Neyman-Pearson test for identifying variable importance[J].IEEE Transactions on Neural Networks and Learning Systems, 2015(26): 880-886.

[20] G Ditzler, M Roveri. Adaptive models in uncertain environments[J]. IEEE Computational Intelligence Magazine, 2015.

[21] D Green, L Payne, R Polikar. P50: A candidate ERP biomarker of prodromal Alzheimer's disease[J]. Brain Research, 2015(16): 390-397.

[22] 周兴勤. 基于选择性集成的增量学习研究[D].重庆大学,2014.

[23] K Ma, J Benarie. Compound Exemplar Based Object Detection by Incremental Random Forest[C]// International Conference on Pattern Recognition. IEEE, 2014:2407-2412.

[24] J R Bertini, M D Nicoletti, L Zhao. Ensemble of complete P-partite graph classifiers for non-stationary environments[C]// Evolutionary Computation. IEEE, 2013:1802-1809.

[25] G Ditzler, R Polikar. Incremental Learning of Concept Drift from Streaming Imbalanced Data[M]. IEEE Educational Activities Department, 2013.

[26] R Elwell, R Polikar. Incremental Learning of Concept Drift in Nonstationary Environments[M]. IEEE Press, 2011.

[27] P Li, X Wu, X Hu, et al. Learning concept-drifting data streams with random ensemble decision trees[J]. Neurocomputing, 2015, 166(C):68-83.

[28] X C Yin, K Huang, H W Hao. DE2 : Dynamic ensemble of ensembles for learning nonstationary data[J]. Neurocomputing, 2015, 165:14-22.

[29] H M Gomes，J P Barddal. A Survey on Ensemble Learning for Data Stream Classification[J]. ACM Computing Surveys ,2017,50(2):23:1-23:36.

中国知网 https://www.cnki.net

[30] V Losing, B Hammer, H Wersing. Incremental on-line learning: A review and comparison of state of the art algorithms[J].Neurocomputing. 2018,275:1261-1274.

[31] Hansen L K , Salamon P . Neural Network Ensembles[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1990, 12(10):993-1001.

[32] L Breiman.Bagging predictors[J]. Machine Learning , 1996,24 (2).

[33] R E Schapire. The strength of weak learnability[J].Machine Learning, 1990,5(2) : 197-227.

[34] L G Valiant. A theory of the learnable[J]. Communications of ACM, 1984, 27(11).

[35] Y Freund, R E Schapire. A Decision-Theoretic Generalization of OnLine Learning and an Application to Boosting[J]. Journal of Computer and System Sciences,1997,55(1):119-139.

[36] T J WANG，F WU，X Y JING．Semi-supervised Ensemble Learning Based Software Defect Prediction．Pattern Recognition and Artificial Intelligence,2017,30(7) : 646－652.

[37] 高翔. 基于语音的抑郁识别集成学习研究[D].兰州大学,2017.

[38] 邹权,宋莉,陈文强,曾建沧,林琛. 基于集成学习和分层结构的多分类算法[J]. 模式识别与人工智能,2015,28(09):781-787.

[39] Z H Zhou, J X Wu, W Tang. Ensembling neural networks: Many could be better than all[J]. Artificial Intelligence, 2002,137(1-2):239-263.

[40] Y Zhang, S Burer, W N Street. Ensemble pruning via semidefinite programming[J]Journal of Machine Learning Research, 2006,(7):1315-1338.

[41] I Partalas, G Tsoumakas, I Vlahavas. Pruning an ensemble of classifiers via reinforcement learning[J]. Neurocomputing, 2009, 72(7-9): 1900-1909.

[42] 赵强利,蒋艳凰.基于 FP-Tree 的快速选择性集成算法[J].软件学报,2011, 22(4):709-721.

[43] 张春霞,张讲社.选择性集成学习算法综述[J].计算机学报, 2011, 34(8):1399-1410.

[44] N Li, Y Yu, Z H Zhou. Diversity Regularized Ensemble Pruning[C]. ECML PKDD'12 Proceedings of the 2012 European conference on Machine Learning and Knowledge Discovery,2012:330-345.

[45] 方育柯,傅彦.基于选择性集成的最大化软间隔算法[J].软件学报,2012,23(5):1132-1147.

[46] 周红芳,王啸.基于频繁模式的选择性集成[J].应用科学学报.2013(06):628-632.

[47] 赵强利. 基于选择性集成的在线机器学习关键技术研究[D].国防科学技术大学,2010.

[48] P Domingos，G Hulten. Mining high-speed data streams[C]//Proceedings of the sixth ACM SIGKDD international conference on Knowledge discovery and data mining, 2000:71-80.

[49] L Li , Q Hu , X Wu , et al. Exploration of classification confidence in ensemble learning[J]. Pattern Recognition, 2014, 47(9):3120-3131.

[50] Z H Zhou, J Wu, W Tang. "Ensembling neural networks: many could be better than all"[J]. Artificial Intelligence, 2002, 137(1-2):239-263.

中国知网 https://www.cnki.net

[51] K Woods, W P Kegelmeyer, K W Bowyer. Combination of multiple classifiers using local accuracy estimates[J]. IEEE Transactions on Pattern Analysis Machine Intelligence,1997,19(4):405-410.

[52] G. M Muñoz, D. H Lobato, A Suarez. An analysis of ensemble pruning techniques based on ordered aggregation[C]//IEEE Trans. Pattern Anal. Mach. 2009: 245–259.

[53] S Soares, C H Antunes, A Rui. Comparison of a genetic algorithm and simulated annealing for automatic neural network ensemble development[J]. Neurocomputing, 2013, 121(18):498-511.

[54] L Wei, S Wan, J Guo, et al. A novel hierarchical selective ensemble classifier with bioinformatics application[J]. Artificial Intelligence in Medicine, 2017,83:82-90.

[55] G Hulten, L Spencer, P Domingos. Mining time-changing data streams [C]//Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, United states, 2001,26-29:97-106.

[56] E J Spinosa, A Carvalhoa. On-Line Novelty detection with application to data stream [J]. Intelligent Data Analysis, 2009, 13(3):405-422.

[57] 姚远. 海量动态数据流分类方法研究[D].大连理工大学,2013.

[58] G J Ross , N M Adams , Tasoulis D K , et al. Exponentially weighted moving average charts for detecting concept drift[J]. Pattern Recognition Letters, 2012, 33(2):191-198.

[59] Z H Zhou, N V Chawla, Y Jin, et al. Big data opportunities and challenges: discussions from data analytics perspectives [J]. IEEE Computational Intelligence Magazine, 2014, 9(4):62-74.

[60] S Grossberg. Nonlinear neural networks: principles, mechanisms, and architectures[J]. Neural Networks, 1988, 1(1):17-61.

[61] P Domingos, G Hulten. Mining high-speed data streams[C]//Proceedings of the 6th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, Boston, 2000: 71-80.

[62] C Koby, D Ofer, K Joseph. Online passive-aggressive algorithms[J]. JMLR. 2006,7(3):551-585.

[63] B Krawczyk, L L Minku, J Gama, et al. Ensemble learning for data stream analysis: A survey[J]. Information Fusion, 2017,37:132-156.

[64] J P Barddal, A Bifet. A Survey on ensemble learning for data stream classification[J]. ACM Computing Surveys, 2017, 50(2):23.

[65] G Ditzler, M Roveri, C Alippi, et al. Learning in Nonstationary Environments: A Survey[J]. IEEE Computational Intelligence Magazine, 2015, 10(4):12-25.

[66] L Zhu, K Ikeda, S Pang, et al. Merging weighted SVMs for parallel incremental learning[J]. Neural Networks, 2018, 100(4):25-38.

[67] G Ditzler, R Polikar. Incremental learning of Concept Drift from streaming imbalanced data[J].

中国知网 https://www.cnki.net

IEEE Transactions on Knowledge and Data Engineering, 2013, 25(10):2283-2301.

[68] D Brzezinski, J Stefanowski. Combining block-based and online methods in learning ensembles from concept drifting data streams[J]. Information Sciences, 2014, 265:50-67.

[69] S Wang, L L Minku, X Yao. Resampling-based ensemble methods for online class imbalance learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2015, 27(5):1356-1368.

[70] A Tsymbal, M Pechenizkiy, C Padraig, et al. Dynamic integration of classifiers for handling Concept Drift[J]. Information Fusion, 2008, 9(1):56-68.

[71] 叶青,卢梓豪,周洁.基于近邻分类的增量学习分类算法研究[J].计算机工程与应用, 2016, 52(20): 154-157.

[72] 韩妍妍, 冯筠, 崔鑫等.动态多分类器集成在肺结节辅助检测中的应用[J]. 计算机工程与应用, 2012, 48(2):218-221.

[73] X Yang, B Yuan, W Liu. Dynamic weighting ensembles for incremental learning[C]//Conference on Pattern Recognition. IEEE, 2009.

[74] K Woods, P Indyk, T Laarhoven, et al. Practical and optimal LSH for angular distance[C]//Neural Information Processing Systems Conference, 2015.

[75] B Léon. Large-scale machine learning with stochastic gradient descent[C]//In: Proceeding of COMPSTAT, 2010:177-186.

[76] T S Tabatabaei, Karray F , Kamel M S . Adaptive Budget for Online Learning[C]// IEEE International Conference on Data Mining Workshops. IEEE, 2014.

[77] K Tang, M Lin, F Minku, et al. Selective Negative Correlation Learning Approach to Incremental Learning[J]. Neurocomputing, 2009,72(13):2796-2805.

[78] F L Minku, H Inoue, X Yao. Negative correlation in incremental learning[J]. Natural Computing, 2009, 8(2):289-320.

[79] K Jackowski. Fixed-size ensemble classifier system evolutionarily adapted to a recurring context with an unlimited pool of classifiers[J]. Pattern Analysis & Applications, 2014, 17(4):709-724.

[80] C Lin, W Q Chen, C Qiu, et al. LibD3C: Ensemble classifiers with a clustering and dynamic selection strategy[J]. Neurocomputing,2014,123:424-435.

[81] Konrad J . New diversity measure for data stream classification ensembles[J]. Engineering Applications of Artificial Intelligence, 2018, 74:23-34.

[82] D H Wolpert. Stacked generalization[J]. Neural neworks,1992,5(2):241-259.

[83] S Dzeroski, B Zenko. Is Combining Classifiers with Stacking Better than Selecting the Best One?[J]. Machine Learning, 2004, 54(3):255-273.

[84] E Cernadas, D Amorim. Do we need hundreds of classifiers to solve real world classification

中国知网 https://www.cnki.net

problems?[J].Journal of Machine Learning Research,2014,15(1):3133-3181.

[85] M Wozniak, P Kasprzak. Application of combined classifiers to data stream classification[C]//Proceedings of the 10th International Conference on Flexible Query Answering System, Berlin,2013.

中国知网 https://www.cnki.net

附录 A 科研情况

论文：

[1] 熊霖,唐万梅.基于 k-means++的多分类器选择分类研究[J].重庆师范大学学报(自然科学版),2018,35(06):88-96.

[2] 熊霖,唐万梅.一种加入动态权重的AdaBoost算法[J].重庆师范大学学报.自然科学版（录用）

[3] 熊霖,唐万梅.基于异构分类器集成的增量学习算法[J/OL].计算机工程与应用:1-9[2019-04-02].

计算机软件著作权：

[1] 基于 k-means++的多分类器选择分类软件 登记号：2019SR0041982

[2] 高效就业平台信息系统 登记号：2019SR0136547

[3] 加入动态权重的 AdaBoost 分类软件 登记号：2018SR1087607

中国知网 https://www.cnki.net

致　　谢

三年的研究生时光转瞬即逝，回想当初踏入重师这个美丽的校园，仿佛就在昨天，也记得当时的那份喜悦，感觉自己真的很幸运。回首这三年时光，感慨万千。有欢笑，有泪水，有失败的沮丧，更有成功的喜悦。无论是学习还是生活，我认为非常圆满，我也达到了当初我给自己设定的目标，不但做着自己想做的事情，还认识了一群很要好的同学和朋友。在论文接近完稿之际，此刻我想向老师和朋友表达我最诚挚的谢意。

首先感谢我的导师唐万梅教授。唐老师工作上兢兢业业；学术上治学严谨；生活中平易近人。在这三年中，不仅给予我学术上的指导，教会了我专业领域的知识，还有教会我做人的道理以及生活中给予的帮助。在刚开始写论文时，一篇初稿完成，唐老师在百忙之中抽出时间来对我论文字字把关，指导我怎么让人更加容易理解，我感觉写论文不再是一件枯燥的事情，而是一门艺术。很荣幸能成为唐万梅老师的学生，唐老师对学术和人生的态度、活到老学到老、无私奉献精神时时刻刻的影响着我，是我学习的榜样，如果有幸成为一名老师，我必定像唐老师那样，为教育事业做出自己的贡献。

其次，我还要非常感谢计算机与信息科学学院给我们提供了这么良好的学习条件和这么浓郁的学术氛围；感谢计算机与信息科学学院的老师们对我的教导，正是因为有他们无私、高质量的教导，我才能在这几年学习过程中吸取专业知识和迅速提升专业能力；感谢我的同学们，是这个友爱的大家庭，让我不觉得离家的孤单；是这个友爱的大家庭，让我在学术上遇到困惑时，不至于手足无措；是这个友爱的大家庭，推动我一起成长。

感谢我的父母，含辛茹苦的把我养大，给予我全部的理解与支持，每当我受挫时，总能给予我安慰和鼓励。这里想引用张伯伦的《你的孩子其实并不是你的孩子》感谢他们，你的孩子，其实不是你的孩子，他们是生命对于自身渴望而诞生的孩子。他们通过你来到这世界，却非因你而来，他们在你身边，却并不属于你。你可以给予他们的是你的爱，却不是你的想法，因为他们自己有自己的思想。你可以庇护的是他们的身体，却不是他们的灵魂，因为他们的灵魂属于明天，属于你做梦也无法达到的明天。你可以拼尽全力，变得像他们一样，却不要让他们变得和你一样...

最后，我要感谢百忙中抽出时间参加我毕业答辩和评审我论文的各位专家，百忙之中审阅我的论文，并恳请提出宝贵的意见和建议，让我能够明确今后的研究方向，这对我来说是一笔无价的财富。

谨以此文献给所有关心和支持过我的老师、同学、亲人和朋友们，是你们的

中国知网 https://www.cnki.net

无私帮助让我度过研究生这段令人难忘的时光，谢谢！

中国知网 https://www.cnki.net