基于异构分类器集成的增量学习算法

熊 霖,唐万梅
重庆师范大学 计算机与信息科学学院,重庆 401331

摘 要:将集成学习的思想引入到增量学习之中可以显著提升学习效果,近年关于集成式增量学习的研究大多采用加权投票的方式将多个同质分类器进行结合,并没有很好地解决增量学习中的稳定-可塑性难题。针对此提出了一种异构分类器集成增量学习算法。该算法在训练过程中,为使模型更具稳定性,用新数据训练多个基分类器加入到异构的集成模型之中,同时采用局部敏感哈希表保存数据梗概以备待测样本近邻的查找;为了适应不断变化的数据,还会用新获得的数据更新集成模型中基分类器的投票权重;对待测样本进行类别预测时,以局部敏感哈希表中与待测样本相似的数据作为桥梁,计算基分类器针对该待测样本的动态权重,结合多个基分类器的投票权重和动态权重判定待测样本所属类别。通过对比实验,证明了该增量算法有比较高的稳定性和泛化能力。

关键词:增量学习;集成学习;局部敏感哈希;异构分类器集成;动态权重
文献标志码:A **中图分类号:**TP391 doi:10.3778/j.issn.1002-8331.1812-0188

熊霖,唐万梅.基于异构分类器集成的增量学习算法.计算机工程与应用,2020,56(7):155-161.
XIONG Lin, TANG Wanmei. Incremental learning algorithm based on heterogeneous classifier ensemble. Computer Engineering and Applications, 2020, 56(7):155-161.

Incremental Learning Algorithm Based on Heterogeneous Classifier Ensemble

XIONG Lin, TANG Wanmei
College of Computer and Information Science, Chongqing Normal University, Chongqing 401331, China

Abstract: Introducing the idea of ensemble learning into incremental learning can improve the learning effect. In recent years, most of the research on ensemble incremental learning combines multiple homogeneous classifiers with weighted voting method, which does not solve the problem of stability-plasticity in incremental learning very well. An incremental learning algorithm based on heterogeneous classifier ensemble is proposed. In the stage of training, to make the ensemble model more stable, many base classifiers are trained with new data and then append into heterogeneous ensemble model. Meanwhile, Locality-Sensitive Hashing is used to save the data sketch for the nearest neighbor search of test sample. In order to adapt to the changing data, the newly acquired data will be used to update the voting weight of the base classifier in the ensemble model. In the prediction stage, for the class label prediction of the test sample, the data similar to the test sample is found from the Local-Sensitive Hashing table, this data is used as a bridge to calculate the dynamic weight of the base classifier for the test sample. It determines the class label of the test sample by combined the voting weight and dynamic weight of many base classifiers. Through comparative experiments, it is proved that the proposed algorithm has well stability and generalization ability.

Key words: incremental learning; ensemble learning; Locality-Sensitive Hashing(LSH); heterogeneous classifiers ensemble; dynamic weight

1 引言

机器学习是人工智能领域的主要研究方向之一,目前的大多数算法均采用批量学习的方式[1],若对新的数据进行学习,需要丢弃已经训练好的模型,将新数据加

基金项目:国家自然科学基金面上项目(No.11671062);重庆市教育规划重点项目(No.2017-GX-116)。
作者简介:熊霖(1992—),男,硕士研究生,研究领域为机器学习与数据挖掘;唐万梅(1965—),通信作者,女,博士,教授,研究方向为神经网络、数据挖掘、机器学习,E-mail:1093895431@qq.com。
收稿日期:2018-12-17 **修回日期:**2019-03-25 **文章编号:**1002-8331(2020)07-0155-07
CNKI **网络出版:**2019-03-28, http://kns.cnki.net/kcms/detail/11.2127.TP.20190326.1831.029.html

计算机工程与应用 www.cnki.net

入原有的数据集之中重新训练新模型。近年来物联网、社交媒体、互联网以及移动通信等领域高速发展,数据流逐渐成为数据分析与挖掘的主角,其主要特点有无限性、实时性、易失性与动态变化性[2]。批量学习方式处理动态数据流会面临如下几个问题:(1)训练样本不能一次性获得,若新数据加入后都重新训练模型,则需要消耗大量的时间。在现实生活中,网站点击量分析、个性化推荐及电力、银行等行业每时每刻都产生着庞大的数据,如果每次获得新数据就重新训练模型是不切实际的。(2)产生数据的环境是变化的,数据流中数据的分布或隐含的知识也发生着变化,可能导致以前训练的模型不再适用于当前的数据。(3)数据流潜在的海量性导致数据无法一次性载入内存,从而无法进行完整的批量式学习。

1962年,Coppock和Freund在Science上提出了增量学习[3]方法。增量学习与人脑学习相似,是指在保留以前学到的知识的情况下不断学习来自环境的新知识。在学习过程中,由于新增加的数据相对于原累积的数据来说较少,可以用新数据对原模型进行微调以获得和批量学习相似的效果。然而设计增量学习算法必定会面对稳定-可塑性难题[4]:稳定性是指模型必须要保存已经学过的知识,意味着模型的参数和结构不能改变;而可塑性是指为了学习新知识需要对模型的参数与结构进行调整。增量学习根据所用分类器的多少可以分为单分类器增量学习和集成式增量学习。单分类器增量学习指在学习过程中只用一个模型,模型会根据新样本调整其内部结构或者参数以适应数据的变化,具有很好的可塑性,但稳定性不高。有代表性的单分类器模型有Hoeffding树[5]、在线被动攻击算法[6]等,这需要所使用的基分类器本身具备增量学习能力。经大量实验表明:集成学习可以提高增量学习算法的稳定性和预测准确率[7],集成式增量学习以Learn++算法[8]、SEA算法[9]为代表,使用多个分类器对数据进行增量学习,对所用的分类器是否具备增量学习能力没有要求,这种方法具有很好的稳定性,但其可塑性低,难以应对数据产生突变或者渐变等情况。文献[10-12]对当前流行的多种增量学习算法进行了比较和归纳,可以看出近几年提出的集成式增量学习算法如wESVM[13]、Learn++.CDS[14]、OAUE[15]、WEOB[16]等大多是集成多个同质分类器,采用加权投票的方式对分类器进行结合的。为应对集成模型可塑性差的问题,多数算法采用动态权重的方式对分类器进行结合,如文献[16-20],在计算动态权重过程中,查找待测样本的近邻时会计算整个数据集中的数据与待测样本的距离,这样的方式极为耗时。尤其对于数据流,大量数据的存储与计算将会产生巨大的时空开销。

针对以往集成式增量学习中没有很好的权衡稳定-可塑性问题和计算动态权重耗时问题,本文提出了一种异构分类器集成的增量学习算法(Incremental learning algorithm based on Heterogeneous Classifier Ensemble,IHCE),在保证算法稳定性的前提下,兼顾算法对动态数据的适应性,获得快速而准确的增量学习模型。主要采用局部敏感哈希(Locality-Sensitive Hashing,LSH)来保存数据分布的梗概,用异构的分类器集成模型对不断变化的数据流进行增量学习。在对待测样本做预测时,根据待测样本与基分类器的适应性,调整基分类器的投票权重,以应对数据发生变化等情况。

2 局部敏感哈希(LSH)

对于海量高维的数据流,数据流中有很多近似重复记录,可以采用将相似度很高的数据进行剔除,压缩数据得到数据流分布的梗概。以往的算法查找待测样本的近邻多是采用直接计算每个训练样本与待测样本间的欧氏距离[7,11],这种方法会花费大量的时间,可以采用类似索引技术来加快查找过程。在提出的IHCE算法中,采用LSH[21]的方式来剔除数据流中近似重复数据和查找待测样本的近邻。LSH是一种高维空间最近邻搜索算法,其基本思想是:通过hash函数把数据从高维空间映射到低维空间中,使得高维空间的相似数据在低维空间相似概率很高;而在高维空间不相识的数据在低维空间相似概率很低,其形式化定义如下。

定义1(局部敏感哈希函数簇) 对于Hash函数簇 H 中每个函数 h,如果任意两点 p、q 满足以下条件,则认为 H 是($dist_1, dist_2, P_1, P_2$)-sensitive的:

(1)若 $d(p,q)\leqslant \mathrm{dist}_1$, 则 $\mathrm{Pr}_H[h(p)=h(q)]\geqslant P_1$;

(2)若 $d(p,q)\geqslant dist_2$, 则 $\mathrm{Pr}_H[h(p)=h(q)]\leqslant P_2$。

其中, $dist_1<dist_2, 1\geqslant P_1>P_2\geqslant 0, d(p,q)$ 为 p、q 两点的距离, $\mathrm{Pr}_H[]$ 表示 p、q 两点的哈希值相同的概率。条件(1)保证两个相似点以高概率被映射进同一个哈希桶;条件(2)保证两个不相似的点以低概率映射进同一个哈希桶。

局部敏感哈希常用的距离度量有汉明距离、欧式距离和余弦距离,通常较高维的数据采用余弦距离度量较好,给定 n 维的两个样本点 p 和 q,两者的相似性为:

$$\cos(\theta)=\frac{\sum_{i=1}^{n}(p_i\times q_i)}{\sqrt{\sum_{i=1}^{n}(p_i)^2}\times\sqrt{\sum_{i=1}^{n}(q_i)^2}} \tag{1}$$

公式(1)表示 p、q 两点向量之间的夹角余弦值,值越大,则两点越相似。

3 IHCE算法

集成式增量学习在训练阶段,通常是用新获得的数据块训练一个或者多个基分类器加入到集成分类器

计算机工程与应用 www.cnki.net

中。如何将基分类器进行结合是集成式增量学习最为关键的一步,在以往的大多数研究中,多采用加权投票的方式进行结合,基分类器权重来源于该分类器在当时训练集上的分类能力,也就是说基分类器一旦训练完成,分类器的权重在预测不同的待测样本时是不变的。有可能基分类器当时在训练集上分类能力好,获得较高的权重,但对预测数据的分类能力差。这在数据流中尤为常见,所以针对实时的数据调整基分类器投票权重显得非常重要。

IHCE算法主要从三方面入手:(1)采用异构的方式构建集成模型。对于新获得的数据,采用不同的分类算法分别训练分类器可提高基分类器之间差异性。(2)用实时的数据调整基分类器的投票权重,以适应数据的变化。(3)在分类器的预测阶段,兼顾基分类器的历史表现和对待测样本的适应性,得到分类器对当前待测样本更合理的投票权重。算法基本框架如图1所示。

3.1　LSH保存数据分布梗概

IHCE算法在算法训练之初建立一张空的哈希表,针对每个时间段获得的数据块,将数据分别映射到表中多个固定容量的哈希桶中,若一个桶中的数据超过其容量,则用新数据替换最旧的数据。通过对多个数据块的处理,建立一张保存了数据分布梗概的哈希表。

如图2所示,以三维数据为例,用包含4个哈希桶的LSH对3个数据块进行处理。假设B区域数据经哈希映射落入桶2、桶3中,因该区域数据相对于其他区域数据较多且分布广,所以桶2和桶3中的数据更新非常快,这样可以快速适应数据动态的变化;而对于数据分布较少的A区域,桶1中完整地保存3个数据块中A区域的数据,这样可以很好保存数据分布的梗概。

3.2　更新投票权重和训练基分类器

IHCE算法训练阶段,首先会用当前数据块对集成分类器中的每个基分类器进行测试,用该分类器对应的分类准确率更新其投票权重 α ,更新公式如下:

$$\alpha_k^j=\alpha_{k-1}^j+\frac{acc-\alpha_{k-1}^j}{k} \tag{2}$$

式中,acc 是第 k 个数据块上训练的第 j 个基分类器的分类准确率,α_{k-1}^j 是第 j 个基分类器在第 $k-1$ 个数据块上的投票权重。

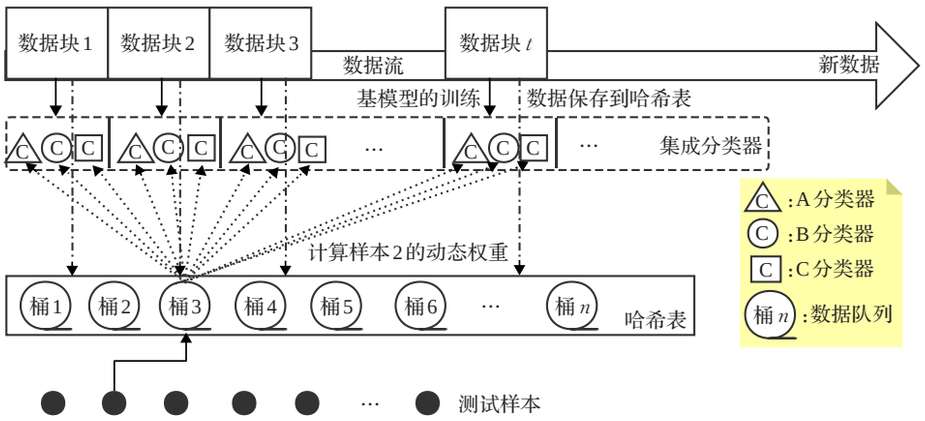

图1　IHCE算法示意图

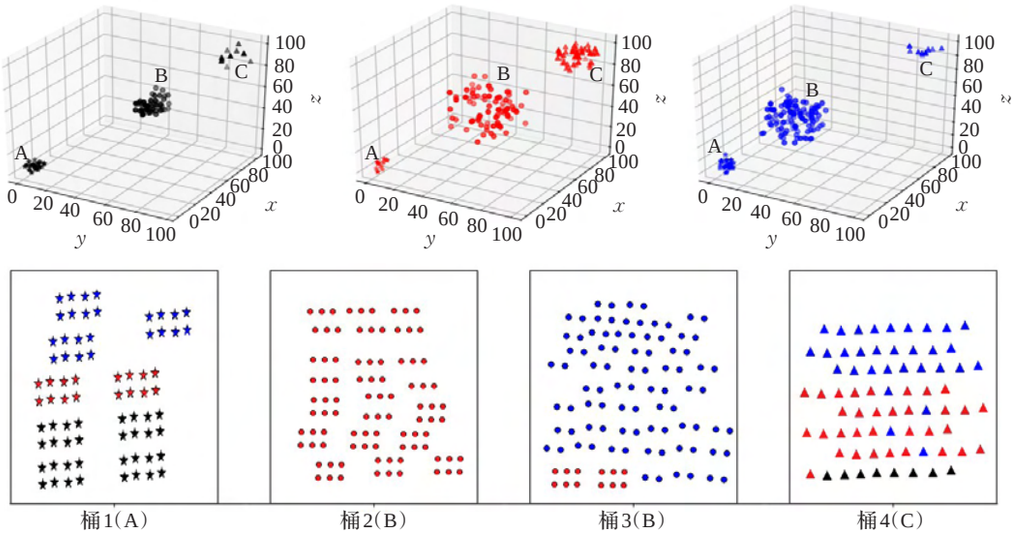

图2　LSH保存数据分布梗概

IHCE算法用异构的方式组建集成模型,对于新获得的数据块,为提高基分类器之间的差异性,用多种不同的分类算法在数据块上分别训练一个基分类器,将训练完成的多个基分类器加入到集成模型中。

3.3　针对待测样本计算基分类器动态权重

IHCE算法预测阶段,加入了能度量待测样本与基分类器适应性的动态权重。算法先从哈希表的桶中找出与待测样本相似的 a 个训练样本,用每个基分类器对这 a 个点进行分类,分类准确率就是该基分类器针对待测样本的动态权重,计算公式如下:

$$\beta_k^j=\frac{1}{a}\sum_{t=1}^{a}(C_k^j(x_t)=y_t) \tag{3}$$

3.4　算法实现

IHCE算法在训练阶段,获得新数据块后,算法主要有三步:(1)用数据对集成模型中的每个基分类器进行测试,用分类准确率更新基分类器的投票权重。(2)将数据块中的数据映射进敏感哈希表的某个桶中,如果该桶已满,则用最新数据替换最旧的数据。(3)用多种不同的分类算法在该数据块上训练多个基分类器,加入到集成模型中。预测阶段由三部分组成:(1)将待测样本映射进某个哈希桶中,可认为该桶中的数据与待测样本是相似的。(2)用这些相似数据去评估基分类器与待测样本的适应性,得到每个基分类器针对待测样本的动态权重 β。(3)将基分类器的投票权重 α 与针对待测样本所获得的动态权重 β 结合得到该基分类器综合权重,用多个基分类器综合权重加权投票判定待测样本的类别。算法流程如图3所示。

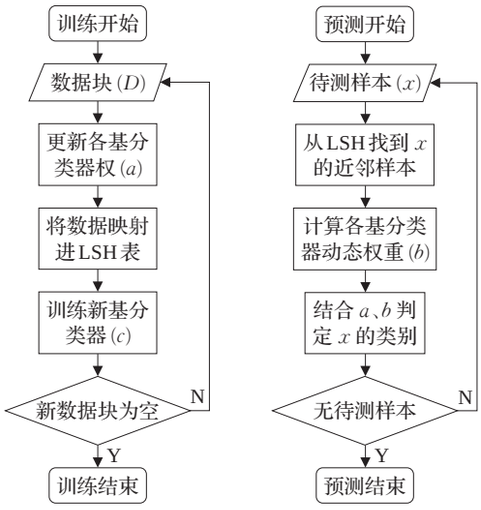

(a)IHCE算法学习流程　(b)IHCE算法分类流程

图3　IHCE算法流程图

IHCE算法描述:

输入:数据流 $DS=\{D_1,D_2,\cdots,D_k\}$,$m$ 种分类算法 $\{A_1,A_2,\cdots,A_m\}$,测试样本 x,哈希桶数量 c 及容量 s。

输出:带投票权重的基分类器集合 E_c,保存数据流梗概的哈希表 HT。

训练过程:

步骤1　(1)创建一张包含了 c 个桶,每个桶容量为 s 的空哈希表 HT。(2)在数据块 D_1 上,用分类算法 $\{A_1,A_2,\cdots,A_m\}$ 训练得到 m 个基分类器 $\{C_1^{A_1},C_1^{A_2},\cdots,C_1^{A_m}\}$,加入集成分类器 E_c。(3)将 D_1 数据映射到哈希表 HT 中。

步骤2　(1)用 D_k 测试 E_c 中的基分类器,使用公式(1)更新基分类器的投票权重。(2)将 D_k 中的数据通过哈希函数映射到哈希表 HT 某个哈希桶中,如果桶容量已满,用最新数据代替最旧的。(3)用 $\{A_1,A_2,\cdots,A_m\}$ 在 D_k 上学习得到 m 个基分类器 $\{C_k^{A_1},C_k^{A_2},\cdots,C_k^{A_m}\}$,加入集成模型 E_c。

步骤3　读入下一数据块,如果数据块为空,结束训练过程;否则回到步骤2。

经过 k 次学习,得到集成模型为:$E_c=\{C_1^{A_1},C_1^{A_2},\cdots,C_1^{A_m},\cdots,C_k^{A_1},C_k^{A_2},\cdots,C_k^{A_m}\}$。

预测样本 x:

步骤4　将 x 通过哈希函数映射到 HT 中,找出与待测样本 x 相似的多个数据组成临时测试集 D_s。

步骤5　对于 E_c 中 $k\times m$ 个基分类器:

每个基分类器 $C_i^j,i=1,2,\cdots,k,j=1,2,\cdots,m$ 分别对 D_s 进行分类测试,用公式(2)计算分类器的动态权重 β_i^j。

最终,对于待测样本 x,集成分类器为:$f(x)=\sum_{i=1}^{k}\sum_{j=1}^{m}\alpha_i^jC_i^j(x)\times\beta_i^j$。

3.5　算法时间复杂度

设 k 为学习次数,n 为获得的数据块大小,有 m 种分类算法。IHCE算法训练阶段的耗时分析:(1)用 m 种分类算法在数据块上训练分类器所需时间是 $O(mn)$。(2)将数据块中数据映射到哈希表所需时间为 $O(n)$。(3)更新 $(k-1)\times m$ 个基分类器的权重所需时间为 $O(n\times(k-1)\times m)$。

预测样本所需时间由两部分组成:首先找待测样本的近邻时间为 $O(1)$,计算基分类器在 a 个近邻数据上的准确率时间为 $O(k-1)\times m\times a)$,$n\gg a$,m 一般情况下较小(<10)。综上所述,当获得一个数据块,IHCE算法处理的时间近似于 $O(n\times k\times m)$。

4　实验结果与分析

本文选择了4种增量学习算法作为对比算法,在9个数据集上做了仿真实验,以验证IHCE算法的有效性。所有实验均在Inter® Core™ i5-4590S@3.00 GHz,Windows 7操作系统上采用Python2.7实现。

计算机工程与应用 www.cea.org

4.1　实验数据集

本文实验数据集来源于UCI数据库中9个真实的数据集。每个数据集中都仅包含两类数据,将数据类标签统一成{+1,−1}两类,将每个数据集等量分成10个数据块,基本信息描述见表1。

表1　实验数据集信息

数据集	样本数	特征数	数据块大小
banknote	1 380	4	138
biodeg	1 060	41	106
sonar	220	60	22
Diabetic	1 160	19	116
liver-disorder	380	6	38
ionoshphere	360	34	36
waveform	3 360	40	336
Crowdsourced	10 560	29	1 056
svmguide	1 260	23	126

4.2　实验设置

本文选择了4个常见的增量学习算法作为对比算法:增量Passive-Aggressive算法[6](IPA)、Learn++算法[8]、Adaptive Budget Perceptron[22](ABP)和增量SGD算法[23](ISGD)。集成模型中的基分类算法统一选用决策树,由于IHCE算法是异构的,因此还加入支持向量机和AdaBoost两种算法。对比算法的参数来源于原文献的实验参数。IHCE算法中的另外两个主要参数分别是:哈希桶的个数和桶容量,增加桶的数量和容量可以提升算法的性能,但会增加存储空间。为了兼顾算法的分类精度和空间开销,经多次实验后,设置哈希桶个数$c=10$,桶容量设置为:数据块中样本数量/100。

每个数据集分成等量的10块,每种算法依次在前9个数据块上进行增量学习,最后1块仅用作分类器每次学习后的测试集。为了使得实验数据更加可靠,重复进行实验5次,并计算分类准确率的平均值。

4.3　实验结果与分析

如图4展示了5种算法训练的分类器随着训练样本的增多在测试集上分类准确率的变化趋势,用折线表示每个分类器对新增数据学习后在测试集上的分类准确率的变化情况。子图中横坐标代表参加训练的数据占整个实验数据集的百分比,纵坐标则是各分类器在测试集上的分类准确率。表2给出了每个实验数据集上,5种分类算法8次增量学习完成后,在测试数据集上的分类准确率(平均值±标准差)。

从图4可以看到,在数据集banknote、svmguide和Diabetic上,5种分类算法训练的分类器随着训练集增加,分类准确率都没有太大的提升,主要是因为增加的训练数据和建立初始模型的数据相似。其余数据集上,IPA和ISGD算法分类准确率有一定的波动,这是因为前后加入训练的数据隐含的类边界发生了较大的改变,这两种算法可塑性高,对数据的变化非常灵敏。而相比之下,IHCE分类器和Learn++分类器由于保留了大量先前学到的知识,用新增训练数据对模型进行微调,从而分类准确率稳步上升。

从总体上看,IHCE算法从最初分类器的建立一直到整个学习过程完成,其分类准确率均比对比算法要高,这是因为该算法在学习过程中不仅保留了所学到的知识,而且根据新增数据实时调整基分类器的投票权重,使得集成分类器能适应数据的变化。用哈希表来保存数据流的梗概,在算法预测阶段,能通过哈希表非常迅速的找到与待测样本相似的数据,针对待测样本加入动态权重,动态地调整每个基分类器的综合权重,使集成模型能很好地应对数据分布发生突变等情况。对于数据块之间没有发生明显分布变化的数据集banknote、svmguide、Diabetic,IHCE算法和对比算法相比分类准确率稍高;对于前后发生明显变化的另6个数据集,IHCE算法比对比算法有更加显著的分类效果。

综合图4和表2的结果可知:当完成9个数据块的增量学习后,本文提出的IHEC算法在8个数据集上的分类准确性都比其他算法要高,其中在biodeg、Crowdsourced和sonar数据集上表现的非常明显,本文算法能较好地兼顾增量学习中的稳定与可塑性,有一定的通用性。

IHCE算法由于在训练阶段会对基分类器权重做实时更新,理论上要比4种对比算法耗时更多。实验过程中发现:ABP、IPA和ISGD算法用时明显少于IHCE和Learn++算法,但IHCE算法在有些数据集上运行所花费的时间甚至比Learn++算法要短。这是因为Learn++算法在训练分类器的过程中,对带权重的样本随机采样用于基分类器的训练,如果训练的基分类器误分类样本权重之和大于0.5,则舍去该基分类器。这就导致Learn++算法需要反复取样来训练基分类器,以达到用户设定的基分类器数量。

综上所述,本文提出的IHCE算法在保留了以前学到的知识的情况下,还能很好地应对数据发生变化等情况。在9个实验数据集上显示:IHCE算法分类准确率通常高于常用的4种增量学习算法[6,8,22-23],而且学习过程更加稳定,说明了本文提出的IHCE算法是有效的。

5　结论

增量学习模型应尽量多保存已经学到的知识,还能很好地应对数据的变化。针对以往集成式增量学习算法的不足,提出了基于多分类器异构的集成式增量学习算法(IHCE)。通过多分类器异构的方式增加了基分类器之间的差异性,用LSH表和多个分类器保留了所学到

计算机工程与应用 www.cea.com.cn

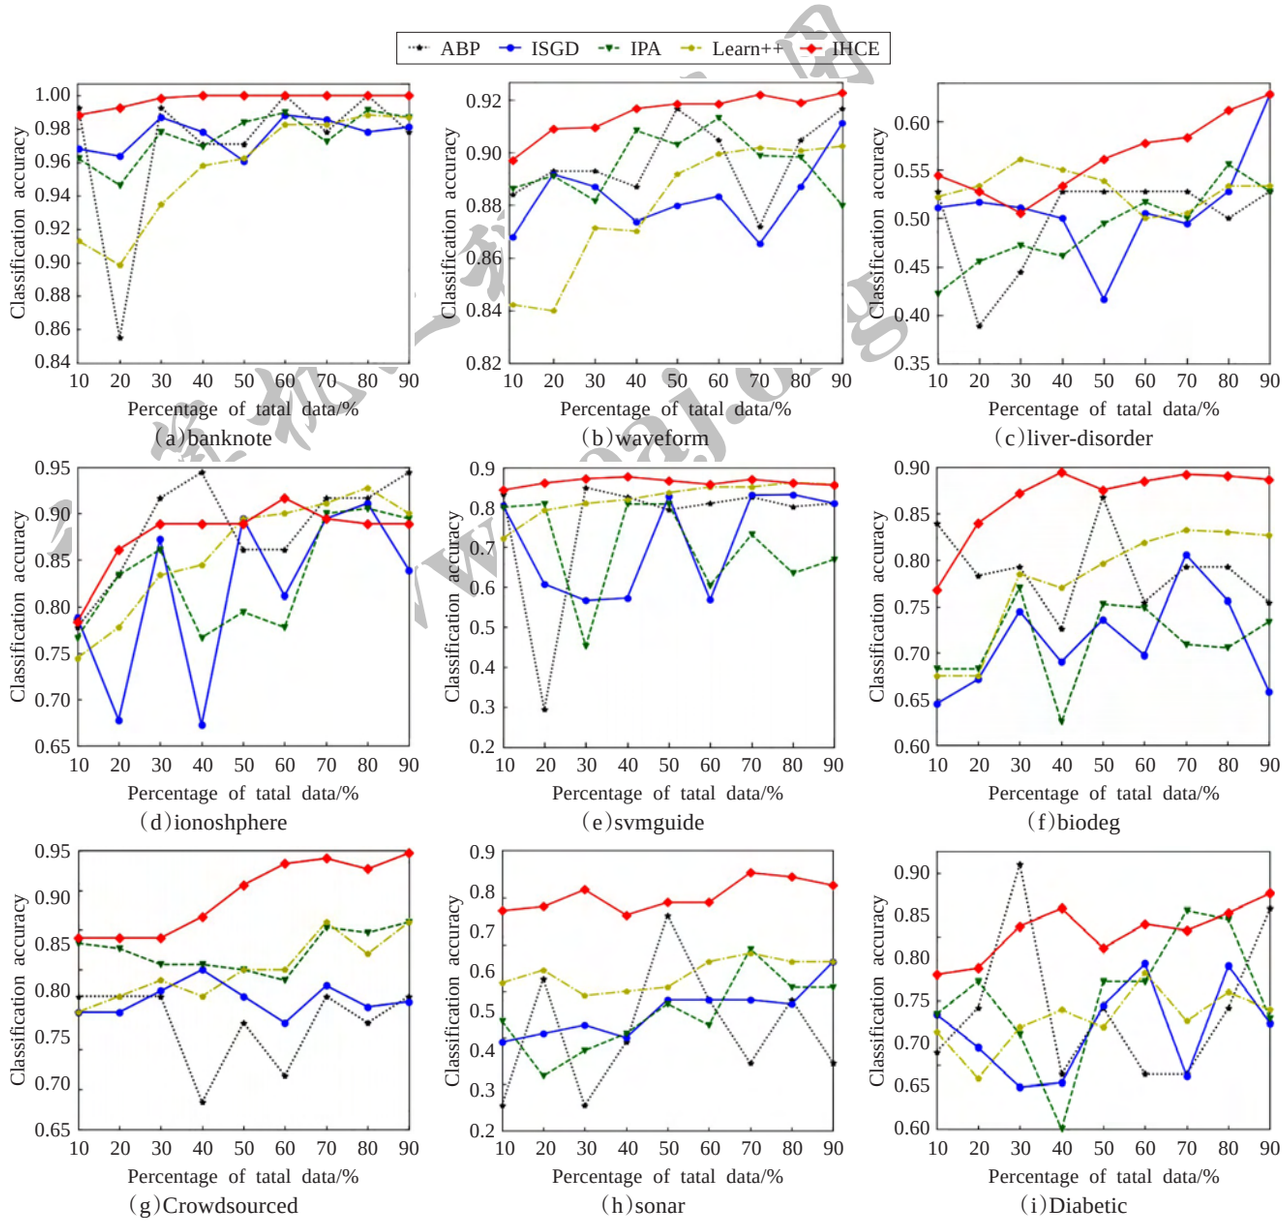

图4　5种算法在9个数据集上增量学习表现

表2　5种算法在9个数据集上学习表现对比　%

数据集	分类准确率				
	ABP	IPA	ISGD	Learn++	IHCE
banknote	97.80±0.00	98.66±1.83	98.11±1.65	98.75±2.77	**99.09±0.09**
liver-disorder	52.77±0.00	52.70±3.73	62.72±9.13	53.34±1.77	**62.77±1.50**
Diabetic	67.26±0.03	58.57±0.76	58.29±0.89	59.71±0.74	**68.60±3.08**
biodeg	75.47±0.08	73.39±0.87	65.87±2.03	82.57±2.33	**88.46±0.92**
ionoshphere	**94.41±0.01**	89.53±2.32	83.88±1.65	90.00±5.14	89.88±0.24
waveform	91.66±0.00	87.99±4.83	91.15±0.98	90.29±2.85	**92.24±0.67**
Crowdsourced	56.67±0.01	66.02±0.86	50.07±0.59	66.52±0.21	**74.62±2.94**
svmguide	81.95±0.42	69.76±9.34	71.82±6.06	79.53±2.94	**85.47±1.09**
sonar	54.55±0.01	70.95±7.25	76.36±9.55	76.80±7.71	**92.74±5.18**

的知识,实时更新基分类投票权重,并在预测阶段加入针对待测样本的动态权重,以调整基分类器的综合权重,使得模型适应数据动态的变化,在多个数据集上的仿真实验证明了该算法能较好地应对增量学习中稳定-可塑性难题,是有效的。但IHCE算法和大多数集成式增量学习算法一样,随着学习的进行,模型规模会变得比较庞大。今后,在提高分类准确率的同时提高算法运行速率还需要进一步研究。

参考文献:

[1] Littlestone N.From on-line to batch learning[C]//Proceedings of Workshop on Computational Learning Theory, San Francisco,1989:269-284

[2] Zhou Z H,Chawla N V,Jin Y,et al.Big data opportunities and challenges:discussions from data analytics perspectives[J].IEEE Computational Intelligence Magazine,2014,9(4):62-74.

[3] Coppock H W,Freund J E.All-or-none versus incremental learning of errorless shock escapes by the rat[J].Science,1962,135:318-319.

[4] Grossberg S.Nonlinear neural networks:principles,mechanisms,and architectures[J].Neural Networks,1988,1(1):17-61.

[5] Domingos P,Hulten G.Mining high-speed data streams[C]//Proceedings of the 6th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining,2000:71-80.

[6] Koby C,Ofer D,Joseph K.Online passive-aggressive algorithms[J].JMLR,2006,7(3):551-585.

[7] Krawczyk B,Minku L L,Gama J,et al.Ensemble learning for data stream analysis:A survey[J].Information Fusion,2017,37:132-156.

[8] Polikar R,Upda L,Upda S S,et al.Learn++:An incremental learning algorithm for supervised neural networks[J].IEEE Transactions on Systems,2001,31(4):497-508.

[9] Street W N,Kim Y S.A Streaming Ensemble Algorithm (SEA) for large-scale classification[C]//Proceedings of ACM SIGKDD International Conference on Knowledge Discovery & Data Mining,2001:377-382.

[10] Losing V,Hammer B,Wersing H.Incremental on-line learning:A review and comparison of state of the art algorithms[J].Neurocomputing,2018,275:1261-1274.

[11] Barddal J P,Barddal J P,Bifet A.A survey on ensemble learning for data stream classification[J].ACM Computing Surveys,2017,50(2):23.

[12] Ditzler G,Roveri M,Alippi C,et al.Learning in nonstationary environments:A survey[J].IEEE Computational Intelligence Magazine,2015,10(4):12-25.

[13] Zhu L,Ikeda K,Pang S,et al.Merging weighted SVMs for parallel incremental learning[J].Neural Networks,2018,100(4):25-38.

[14] Ditzler G,Polikar R.Incremental learning of concept drift from streaming imbalanced data[J].IEEE Transactions on Knowledge and Data Engineering,2013,25(10):2283-2301.

[15] Brzezinski D,Stefanowski J.Combining block-based and online methods in learning ensembles from concept drifting data streams[J].Information Sciences,2014,265:50-67.

[16] Wang S,Minku L L,Yao X.Resampling-based ensemble methods for online class imbalance learning[J].IEEE Transactions on Knowledge and Data Engineering,2015,27(5):1356-1368.

[17] Tsymbal A,Pechenizkiy M,Padraig C,et al.Dynamic integration of classifiers for handling concept drift[J].Information Fusion,2008,9(1):56-68.

[18] 叶青,卢梓豪,周洁,等.基于近邻分类的增量学习分类算法研究[J].计算机工程与应用,2016,52(20):154-157.

[19] 韩妍妍,冯筠,崔鑫,等.动态多分类器集成在肺结节辅助检测中的应用[J].计算机工程与应用,2012,48(2):218-221.

[20] Yang X,Yuan B,Liu W.Dynamic weighting ensembles for incremental learning[C]//Proceedings of Conference on Pattern Recognition,2009.

[21] Andoni A,Indyk P,Laarhoven T,et al.Practical and optimal LSH for angular distance[C]//Proceedings of Neural Information Processing Systems Conference,2015.

[22] Tabatabaei T S,Karray F,Kamel M S.Adaptive budget for online learning[C]//Proceedings of IEEE International Conference on Data Mining Workshops,2014.

[23] Léon B.Large-scale machine learning with stochastic gradient descent[C]//Proceeding of COMPSTAT,2010:177-186.

计算机工程与应用 www.ceaj.org